

Podsumowania lingwistyczne — notatka egzaminacyjna

Odpowiedzi do zagadnień (MK — szczegółowo, AN — skrótowo)

*Notatka odpowiada na zebrane zagadnienia egzaminacyjne. Część **MK** (nasz prowadzący) jest rozwinięta dokładnie, część **AN** skrótowo, ale z kompletem pojęć. Każda odpowiedź jest osadzona w faktycznej implementacji projektu — w nawiasach podaję klasy/pliki, w których dane pojęcie żyje w kodzie. Domena przykładów: samochody (moc silnika, masa, długość, spalanie).*

Spis treści

Mini-słownik	1
CZĘŚĆ I — MK	2
1 Kardynalność (liczność) zbioru rozmytego	2
2 Suma i iloczyn zbiorów rozmytych (i alternatywne normy)	2
3 Dopełnienie zbioru	3
4 Operacje na zbiorach — zestawienie i własności	4
5 Miara T8 — kardynalność sumaryzatora	4
6 Miara T11 — długość kwalifikatora	5
7 Dwie formy wyrażen kwantyfikowanych lingwistycznie	5
8 Zadanie: policzenie kardynalności dla zbioru	6
CZĘŚĆ II — AN	7

9	Zbiory, nośnik, α -przekrój, poziom rozmytości	7
10	Zmienna lingwistyczna	7
11	Kwantyfikatory	8
12	Paradoks Poincaré’a	8
13	Relacje rozmyte: zwrotność, symetria, przechodniość	9
14	Podobieństwo: sąsiedztwo vs rozmyta równoważność	9
15	Miary jakości — pojęcia AN	10
16	Forma 2 podsumowania — i co liczy się szybciej	11
	Szybka ściągą	12

Mini-słownik (żeby wszystko miało wspólny język)

- **Przestrzeń rozważań** X — zbiór wszystkich możliwych wartości cechy (np. moc $\in [0, 600]$ KM). W kodzie `Universe` (próbkowana siatką punktów).
- **Zbiór rozmyty** A — przypisuje każdemu $x \in X$ stopień przynależności $\mu_A(x) \in [0, 1]$ (zamiast twardego 0/1). W kodzie `FuzzySet` + funkcja przynależności `MembershipFunction`.
- **Etykieta** — słowo języka naturalnego (np. „mocny”) sklejone z jednym zbiorem rozmytym (`Label`).
- **Zmienna lingwistyczna** — cecha (np. „Moc silnika”) wraz z zestawem etykiet (`LinguisticVariable`).
- **Σ -count** — suma stopni przynależności (uogólnienie „liczby elementów” na zbiory rozmyte). To kluczowe narzędzie liczbowe całego projektu.

Część I — MK (rozwinęta)

1 Kardynalność (liczność) zbioru rozmytego

Pytanie: Kardynalność / liczba kardynalna zbioru rozmytego.

W zbiorze *klasycznym* kardynalność to po prostu liczba elementów. W zbiorze *rozmytym* element należy „po trochu”, więc zamiast liczyć sztuki, **sumujemy stopnie przynależności**. To tzw. Σ -count (skalarna liczność):

$$|A| = \Sigma\text{count}(A) = \sum_{x \in X} \mu_A(x).$$

Intuicja: jeśli trzy auta należą do zbioru „mocny” w stopniach 1,0, 0,6 i 0,3, to „jest tam” 1,9 mocnego auta — nie całe trzy, bo dwa pasują tylko częściowo.

Względna kardynalność dzieli licznosc przez rozmiar przestrzeni: $\|A\| = |A|/|X|$. W projekcie liczona numerycznie jako *średni stopień przynależności* po próbkach przestrzeni — `FuzzySet.relativeSigmaCardinality()`:

$$\|A\| = \frac{1}{|X|} \sum_{x \in X} \mu_A(x).$$

Gdzie to działa w projekcie. Cały aparat miar jakości stoi na Σ -countach: stopień prawdziwości T_1 liczy $\frac{1}{m} \sum_i \mu_S(d_i)$ (to Σ -count sumaryzatora po rekordach), a miary kardynalności T_7, T_8, T_{10} używają względnej kardynalności zbiorów (`relativeSigmaCardinality()`).

Uwaga — dwie różne „licznoci”. Projekt rozróżnia:

- *licznosc* Σ -count = $\sum \mu(x)$ — bierze pod uwagę kształt funkcji (pole pod nią);
- *licznosc nośnika* = ile punktów ma $\mu > 0$ (`relativeSupportCardinality()`) — bierze tylko szerokość, ignoruje wysokość. To jest „poziom rozmytości” $\text{in}(A)$ (patrz §9).

2 Suma i iloczyn zbiorów rozmytych (i alternatywne normy)

Pytanie: Suma, iloczyn zbioru — co to, do czego, oraz „inaczej suma” (s-norma).

To rozmyte odpowiedniki logicznych **OR** i **AND**. W projekcie zdefiniowane w `Operations` (dekoratory funkcji przynależności) i wystawione przez `FuzzySet.union/intersect`:

Iloczyn (AND): $\mu_{A \cap B}(x) = \min(\mu_A(x), \mu_B(x))$, Suma (OR): $\mu_{A \cup B}(x) = \max(\mu_A(x), \mu_B(x))$.

Do czego służą. Budują *złożone* sumaryzatory i kwalifikatory:

- *Iloczyn* — „auto mocne i ciężkie”. Liczymy min: o ocenie decyduje **najsłabsza** cecha (rygorystyczne „oba warunki naraz”). Auto mocne na 0,9, ale lekkie (ciężkie na 0,2) $\rightarrow$ iloczyn = 0,2.
- *Suma* — „auto szybkie lub tanie”. Liczymy max: wystarczy jedna mocna cecha. Auto powolne (0,1), ale tanie (0,8) $\rightarrow$ suma = 0,8.

„Inaczej suma” — s-norma (i t-norma). min i max to tylko *jeden*, *najpopularniejszy* wybór. Ogólnie:

- iloczyn realizuje dowolna **t-norma** $T(a, b)$ (przemienna, łączna, monotoniczna, $T(a, 1) = a$),
- suma — dowolna **s-norma** (t-konorma) $S(a, b)$ (jak wyżej, ale $S(a, 0) = a$).

Najczęstsze pary (dualne przez dopełnienie $1 - \cdot$):

minimum / maksimum:	$T = \min(a, b)$	$S = \max(a, b)$
algebraiczna:	$T = a \cdot b$	$S = a + b - a \cdot b$
Łukasiewicza:	$T = \max(0, a + b - 1)$	$S = \min(1, a + b)$

Czyli „suma algebraiczna” $a + b - ab$ to alternatywna s-norma; nasz projekt świadomie używa pary min / max (komentarz w `Operations`: „t-norma minimum”, „t-konorma maksimum”). max jest *najmniejszą* możliwą s-normą, min — *największą* t-normą.

3 Dopełnienie zbioru

Pytanie: Dopełnienie zbioru rozmytego.

Rozmyte **NOT**: „w jakim stopniu x *nie* pasuje do A ”. Standardowo (`Operations.complement`):

$$\mu_{\neg A}(x) = 1 - \mu_A(x).$$

Przykład: 210 KM należy do „mocny” w stopniu 0,7, więc do „nie mocny” w stopniu 0,3. W kodzie `FuzzySet.complement()` tworzy nowy zbiór o nazwie „nie ...”.

Ważna różnica względem zbiorów klasycznych. Dla zbiorów rozmytych *nie zachodzą* prawa wyłączonego środka i sprzeczności:

$$A \cup \neg A \neq X, \quad A \cap \neg A \neq \emptyset.$$

Np. przy $\mu_A(x) = 0,5$ mamy $\mu_{A \cap \neg A}(x) = \min(0,5; 0,5) = 0,5 \neq 0$. To nie błąd — to istota rozmytości (element może być „trochę w” i „trochę poza”).

4 Operacje na zbiorach — zestawienie i własności

Pytanie: Operacje na zbiorach.

Trzy podstawowe (wszystkie w `Operations / FuzzySet`), liczone *punkto* po przestrzeni:

Operacja	Wzór	Logika
Dopełnienie	$1 - \mu_A(x)$	NOT
Iloczyn	$\min(\mu_A(x), \mu_B(x))$	AND (t-norma)
Suma	$\max(\mu_A(x), \mu_B(x))$	OR (s-norma)

Własności, które warto znać: przemienność, łączność, rozdzielność, *prawa De Morgana* ($\neg(A \cup B) = \neg A \cap \neg B$ — zachodzą dla pary min / max), idempotentność ($A \cap A = A$). *Nie* zachodzą prawa sprzeczności/wyłączonego środka (patrz wyżej). Warunek poprawności: oba zbiory muszą być nad **tą samą przestrzenią** — w kodzie `union/intersect` przyjmują zbiory nad tym samym `Universe`.

5 Miara T8 — kardynalność sumaryzatora

Pytanie: Cechy miary T8 (stopień kardynalności sumaryzatora).

Za co odpowiada. Mierzy, jak „ostry” (skupiony) jest sumaryzator S — podobnie jak nieprecyzyjność T_2 , ale licząc na *kardynalnościach* (pole pod funkcją), a nie tylko na szerokości nośnika. Dzięki temu odróżnia trójkąt od trapezu o tej samej podstawie. To miara **strukturalna** — zależy od projektu

zbiorów rozmytych, *nie* od danych w bazie.

$$T_8 = 1 - \sqrt[n]{\prod_{j=1}^n \frac{|S_j|}{|X_j|}} = 1 - \sqrt[n]{\prod_{j=1}^n \|S_j\|},$$

gdzie $\|S_j\|$ to względna kardynalność j -tego atomu (w kodzie `relativeSigmaCardinality()`), a n — liczba etykiet w sumaryzatorze (średnia *geometryczna* po atomach).

Zakres i interpretacja. $[0, 1]$; **wyżej** = **ostrzejszy** (węższy względem uniwersum) sumaryzator. W projekcie typowo $\approx 0,88$ – $0,95$ (etykiety są wąskie względem pełnego zakresu cechy).

Implementacja: `QualityMeasures, t8 = 1 - geometricMean(cards)`.

6 Miara T11 — długość kwalifikatora

Pytanie: Cechy miary T11.

Za co odpowiada. Symetryczny odpowiednik T_5 (długość *sumaryzatora*), ale dla **kwalifikatora** W : krótszy kwalifikator (mniej etykiet) = czytelniejsze zdanie. Czysto **formalna** kara za złożoność — nie zależy ani od danych, ani od kształtu zbiorów.

$$T_{11} = 2 \cdot (0,5)^{|W|},$$

gdzie $|W|$ to liczba etykiet w kwalifikatorze.

Zakres: $(0, 1]$; $|W| = 1 \Rightarrow T_{11} = 1$, i maleje *wykładniczo o połowę* z każdą dodaną etykietą ($2 \rightarrow 0,5$, $3 \rightarrow 0,25$).

Kluczowa cecha — istnieje tylko w formie 2. W formie 1 (bez kwalifikatora) $T_{11} = 0$ z definicji. *Uwaga:* T_{11} **nie występuje w książce źródłowej** (Niewiadomski definiuje T_1 – T_{10}). W projekcie dodana przez analogię do T_5 , żeby kwalifikator też miał miarę długości. Implementacja: `t11 = 2.0 * Math.pow(0.5, mr)`.

7 Dwie formy wyrażen kwantyfikowanych lingwistycznie

Pytanie: Dwie formy wyrażen kwantyfikowanych lingwistycznie (formy 1 i 2 podsumowania).

To dwa szablony zdań Zadeha/Yagera. W projekcie buduje je `SingleSubjectSummary`.

Forma 1 (protozdanie, bez kwalifikatora): „ Q P są S ”.

$$T_1 = \mu_Q\left(\frac{1}{m} \sum_{i=1}^m \mu_S(d_i)\right) \quad (\text{kwant. względny}), \quad T_1 = \mu_Q\left(\sum_i \mu_S(d_i)\right) \quad (\text{bezwzględny}).$$

Przykład: „*Większość aut ma standardową długość*”. Liczymy proporcję aut spełniających S i sprawdzamy, czy trafia w kwantyfikator Q .

Forma 2 (z kwalifikatorem W): „ Q P będących W są S ”. W kodzie: „ $[Q]$ aut, które są $[W]$, ma $[S]$ ”. Kwalifikator W zawęża populację (rozmyty odpowiednik WHERE). Stopień prawdziwości liczony **warunkowo**:

$$T_1 = \mu_Q\left(\frac{\sum_{i=1}^m \min(\mu_W(d_i), \mu_S(d_i))}{\sum_{i=1}^m \mu_W(d_i)}\right).$$

Przykład: „*Większość ciężkich aut ma dużą moc*” (W = „ciężki”).

Różnica praktyczna. Forma 1 mówi o *całej* bazie; forma 2 — o *wycinku* (autach spełniających W). Forma 2 aktywuje dodatkowe miary T_9, T_{10}, T_{11} (jakość kwalifikatora), których w formie 1 nie ma (są zerowe).

8 Zadanie: policzenie kardynalności dla zbioru

Pytanie: Policz kardynalność dla (rozmytego) zbioru.

Schemat liczenia (przykład reprezentatywny — liczby zależą od konkretnego zadania). Niech przestrzeń to pięć aut, a zbiór rozmyty A = „mocny silnik” ma stopnie:

$$A = \frac{0,2}{a_1} + \frac{0,8}{a_2} + \frac{1,0}{a_3} + \frac{0,5}{a_4} + \frac{0,0}{a_5}.$$

1. **Kardynalność (Σ -count)** — suma stopni:

$$|A| = 0,2 + 0,8 + 1,0 + 0,5 + 0,0 = \boxed{2,5}.$$

2. **Względna kardynalność** — podziel przez $|X| = 5$:

$$\|A\| = 2,5/5 = \boxed{0,5}.$$

3. **Nośnik i jego licznosc** — elementy z $\mu > 0$: $\text{supp}(A) = \{a_1, a_2, a_3, a_4\}$, więc $|\text{supp}(A)| = 4$, a *poziom rozmytości* $\text{in}(A) = 4/5 = 0,8$.

4. **Wysokość** $= \max_x \mu_A(x) = 1,0 \Rightarrow$ zbiór **normalny**.

Kontrast klasyczny: gdyby zbiór był ostry (tylko 0/1), kardynalność = liczba elementów z przynależnością 1. Σ -count to gładkie uogólnienie: zlicza „częściowe” przynależności.

Część II — AN (skrótowo)

9 Zbiory, nośnik, α -przekrój, poziom rozmytości

Pytanie: Nośnik zbioru i α -przekrój.

Nośnik $\text{supp}(A) = \{x : \mu_A(x) > 0\}$ — wszystko, co należy choć trochę. **α -przekrój** $A_\alpha = \{x : \mu_A(x) \geq \alpha\}$ — wszystko, co należy *przynajmniej* w stopniu α ; ostry (klasyczny) zbiór „wycięty” na wysokości α . Im wyższe α , tym węższy przekrój. Nośnik $\approx$ przekrój dla $\alpha \rightarrow 0^+$, a rdzeń (core) $= A_1$. W kodzie: `FuzzySet.support()` i `alphaCut(alpha)` (zwracają przedział obejmujący).

Pytanie: Co to i do czego „poziom (stopień) rozmytości”.

To miara, jak „rozlany” jest zbiór: $\text{in}(A) = |\text{supp}(A)|/|X|$ (w kodzie `relativeSupportCardinality()`). $\text{in}(A)$ blisko 0 = wąska, precyzyjna etykieta; blisko 1 = rozmazana na całe uniwersum. **Do czego służy:** jest cegielką miar nieprecyzyjności — $T_2 = 1 - \sqrt[n]{\prod \text{in}(S_j)}$, $T_6 = 1 - \text{in}(Q)$, $T_9 = 1 - \text{in}(W)$.

Pytanie: Zbiór rozmyty i jego zastosowanie w reprezentacji informacji lingwistycznych.

Zbiór rozmyty modeluje *nieostre pojęcie języka naturalnego* („mocny”, „duży”, „szybki”), które nie ma twardej granicy. Funkcja μ tłumaczy słowo na liczbę: pozwala maszynie ocenić „190 KM jest mocne w stopniu 0,7”. Dzięki temu możemy budować i *oceniać* zdania w quasi-naturalnym języku — to fundament całego projektu (`FuzzySet` $\rightarrow$ `Label` $\rightarrow$ `LinguisticVariable` $\rightarrow$ podsumowania).

10 Zmienna lingwistyczna

Pytanie: Zmienna lingwistyczna i jej zastosowanie.

To **cecha** (np. „Moc silnika”) wraz z: przestrzenią rozważań, kolumną bazy i **zestawem etykiet** (słów: „słaby”, „średni”, „mocny”), z których każda jest osobnym zbiorem rozmytym (**LinguisticVariable** + lista **Label**). **Zastosowanie:** zamienia surową liczbę z bazy (np. 130 KM) na słowa ze stopniami przynależności — to warstwa „liczby $\rightarrow$ słowa”, bez której nie da się ułożyć zdania podsumowania.

11 Kwantyfikatory

Pytanie: Kwantyfikatory względne i bezwzględne — zastosowanie.

Względny działa na *proporcji* $[0, 1]$ („większość”, „około połowy”) — mówi, jaka *część* obiektów ma cechę. **Bezwzględny** działa na *liczbie* sztuk („około 100 aut”) — mówi o liczności. W projekcie (**Quantifier.Type**) względne mają trapezy na $[0, 1]$, np. „większość” = $(0,60; 0,70; 0,85; 0,95)$, „około połowy” = $(0,30; 0,40; 0,60; 0,70)$. Zastosowanie: argumentem μ_Q jest proporcja (względny) lub sama suma Σ -count (bezwzględny) — patrz T_1 w §7.

Pytanie: Kwantyfikator rozmyty a kwantyfikator lingwistyczny — różnica.

Lingwistyczny to samo *słowo* języka naturalnego („większość”) — pojęcie. **Rozmyty** to jego *matematyczny model*: zbiór rozmyty z funkcją przynależności, którą da się policzyć. Innymi słowy: kwantyfikator lingwistyczny *reprezentujemy* kwantyfikatorem rozmytym. W kodzie świetnie to widać: **Quantifier** trzyma *name* (warstwa lingwistyczna) oraz **FuzzySet** *set* (warstwa rozmyta, czyli model).

12 Paradoks Poincaré’a

Pytanie: Paradoks Poincaré’a.

Dotyczy **nierozróżnialności**. Masy a i $a+1$ grama są dla zmysłów nieodróżnialne ($a \approx a+1$), tak samo $a+1 \approx a+2$ itd., ale a i $a+1000$ są rozróżnialne. Zatem relacja „nierozróżnialne” jest **zwrotna** i **symetryczna**, lecz **nie przechodnia** — łańcuch „równych” kroków daje różnicę widoczną. To pokazuje, że klasyczna relacja równoważności (wymagająca przechodniości) *nie nadaje się* do modelowania percepcji/podobieństwa — stąd potrzeba **relacji sąsiedztwa** (tolerancji) i logiki rozmytej. Łączy się to wprost z pytaniami o relacje niżej.

13 Relacje rozmyte: zwrotność, symetria, przechodniość

Pytanie: Zwrotność i symetria relacji rozmytej — przykłady z języka naturalnego.

Relacja rozmyta to $R : X \times X \rightarrow [0, 1]$ ($R(x, y)$ = stopień, w jakim x jest w relacji z y).

- **Zwrotność:** $R(x, x) = 1$. NL: „każde słowo jest w 100% podobne do samego siebie”; „auto jest tak samo szybkie jak ono samo”.
- **Symetria:** $R(x, y) = R(y, x)$. NL: „jeśli Kowalski jest podobny do Nowaka, to Nowak jest tak samo podobny do Kowalskiego”; „bliski”, „sąsiad”.

Pytanie: Relacja rozmyta przechodnia (tranzytywna) — definicja.

Przechodniość typu max-min:

$$R(x, z) \geq \max_y \min(R(x, y), R(y, z)) \quad \forall x, z.$$

NL: jeśli x jest podobny do y , a y do z , to x musi być podobny do z *przynajmniej* w stopniu najsłabszego ogniwa po najlepszej drodze. (Ogólnie zamiast min dowolna t-norma — T -przechodniość.)

14 Podobieństwo: sąsiedztwo vs rozmyta równoważność

Pytanie: Relacja sąsiedztwa a relacja podobieństwa — cechy i definicja.

Pytanie: Podobieństwo jako relacja sąsiedztwa czy jako rozmyta równoważność?

- **Relacja sąsiedztwa** (tolerancji, proximity): **zwrotna + symetryczna**, *bez* wymogu przechodniości. Rozmyty odpowiednik relacji tolerancji.
- **Relacja podobieństwa** w sensie Zadeha = **rozmyta równoważność**: zwrotna + symetryczna + **przechodnia** (max-min). Rozmyty odpowiednik relacji równoważności.

Cała różnica to przechodniość. I tu wraca Poincaré: realne „podobieństwo” percepcyjne *łapie* przechodniość (łańcuch podobnych obiektów kończy się parą niepodobnych), więc naturalniej modelować je jako **relację sąsiedztwa**, a nie jako ścisłą rozmytą równoważność. Równoważność rozmyta to silniejsze, idealizowane założenie (pozwala na rozmyte klasy abstrakcji).

Pytanie: nGram — czy jest symetryczna?

Miara podobieństwa oparta o n -gramy (liczba/udział wspólnych n -gramów dwóch napisów, np. współczynnik Dice’a) jest **symetryczna** — „wspólne n -gramy a i b ” to to samo co „wspólne n -gramy b i a ”, więc $\text{sim}(a, b) = \text{sim}(b, a)$. Jest też zwrotna ($\text{sim}(a, a) = 1$), ale **nie** przechodnia — więc jest *relacją sąsiedztwa*, a nie rozmytą równoważnością.

Pytanie: Miara podobieństwa a metryka — różnice.

	Metryka $d(x, y)$	Miara podobieństwa $s(x, y)$
Kierunek	$0 =$ identyczne, rośnie z różnicą	$1 =$ identyczne, maleje z różnicą
Tożsamość	$d(x, x) = 0$	$s(x, x) = 1$ (zwrotność)
Symetria	tak	zwykle tak
Nierówność trójkąta	wymagana	nie wymagana
Zakres	$[0, \infty)$	zwykle $[0, 1]$

Krótko: metryka mierzy *odległość* i musi spełniać nierówność trójkąta; miara podobieństwa mierzy *bliskość* (odwrotnie) i nie musi. Często $s = 1 - d_{\text{znorm.}}$, ale nie każde podobieństwo pochodzi od metryki (brak nierówności trójkąta to dokładnie sytuacja sąsiedztwa/Poincaré).

15 Miary jakości — pojęcia AN

Pytanie: Znaczenie miary „stopień nieprecyzyjności”.

Mówi, jak **ostre** są użyte etykiety (a nie co jest w danych). $T_2 = 1 - \sqrt[n]{\prod \ln(S_j)}$ dla sumaryzatora (analogicznie T_6 dla kwantyfikatora, T_9 dla kwalifikatora). **Wyżej = precyzyjniej** (wąskie zbiory względem uniwersum). To miara *strukturalna* — premiuje zdania zbudowane z ostrych pojęć, niezależnie od zawartości bazy.

Pytanie: Miara T3 (stopień pokrycia) — co oznacza dla podsumowania.

Mówi, **jak dużą część rekordów** podsumowanie faktycznie obejmuje (udział aut z $\mu_S > 0$; w formie 2 — udział wśród spełniających kwalifikator). $T_3 = 0,694$ znaczy „dotyczy 69,4% aut”. Razem z T_1 to jedna z dwóch miar realnie zależnych od danych: T_1 mówi *czy prawda*, T_3 — *o ilu obiektach*. Niskie T_3 nie zawsze jest złe (rzadkie, ale prawdziwe i nieoczywiste zdanie).

Pytanie: Cechy miary T5 (dwie).

$T_5 = 2 \cdot (0,5)^{|S|}$ (długość sumaryzatora). Dwie cechy:

1. **Zależy wyłącznie od liczby etykiet $|S|$** — nie od danych, nie od kształtu ani szerokości zbiorów, nie od kwantyfikatora. Czysto formalna kara za złożoność (czytelność).
2. **Maleje wykładniczo o połowę:** $|S|=1 \rightarrow 1$ (najkrótsze, max), $2 \rightarrow 0,5$, $3 \rightarrow 0,25$; wartości w $(0, 1]$.

16 Forma 2 podsumowania — i co liczy się szybciej

Pytanie: Druga forma jednopodmiotowego podsumowania lingwistycznego.

„ Q aut, które są W (kwalifikator), ma S (sumaryzator)” — z kwalifikatorem zawężającym populację. T_1 liczony warunkowo (wzór w §7).

Pytanie: Co liczy się szybciej: S_1 i S_2 bez kwalifikatora (forma 1, sumaryzator złożony) czy S_1 z Q i S_2 jako kwalifikator (forma 2)?

Obie wersje robią **jeden przebieg** po rekordach, więc są tej samej klasy złożoności $O(m \cdot \#atomów)$. Ale **forma 1** (z S_2 **wbudowanym w sumaryzator** jako $\min(\mu_{S_1}, \mu_{S_2})$) liczy się **taniej**, bo:

- potrzebuje tylko jednego akumulatora ($\sum \mu_S$) i prostej średniej, bez warunkowego dzielenia przez $\sum \mu_W$;
- *nie* uruchamia miar kwalifikatora T_9, T_{10}, T_{11} (w formie 1 są zerowe).

W kodzie widać to wprost: gałąź `form2` w `QualityMeasures` dokłada akumulatory `sumR`, `sumRandS`, `countRpos`, `countRSpos` oraz cały blok T_9 – T_{11} . Wniosek: **przeniesienie S_2 do sumaryzatora (forma 1) jest szybsze** niż użycie go jako osobnego kwalifikatora (forma 2), choć rząd złożoności ten sam. Semantycznie jednak liczą *co innego* (forma 1 — „ Q aut jest S_1 i S_2 ”; forma 2 — „ Q spośród aut S_2 jest S_1 ”).

Szybka ściągą — jednym zdaniem

- Iloczyn = min (t-norma, AND), suma = max (s-norma, OR), dopełnienie = $1 - \mu$.
- Kardynalność = Σ -count = $\sum \mu$; względna = to / $|X|$.
- Poziom rozmytości $\text{in}(A) = |\text{supp}|/|X|$; nieprecyzyjność = $1 - \text{in}$.
- Nośnik: $\mu > 0$; α -przekrój: $\mu \geq \alpha$.
- Sąsiedztwo = zwrotna+symetryczna; podobieństwo (rozmyta równoważność) = jeszcze przechodnia. Poincaré: percepcja łamie przechodniość $\Rightarrow$ sąsiedztwo.
- nGram: symetryczna i zwrotna, nieprzechodnia.
- Metryka: 0 = identyczność, nierówność trójkąta wymagana; podobieństwo: 1 = identyczność, bez trójkąta.
- T_3 pokrycie + T_1 prawda = jedyne miary „o danych”; reszta strukturalna/formalna.