

Komputerowe systemy rozpoznawania

2024/2025

Projekt 2. Podsumowania lingwistyczne relacyjnych baz danych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr inż. Marcin Kacprowicz

22 maja 2026

Opis projektu ma formę artykułu naukowego lub raportu z zadania badawczego (doświadczalnego/obliczeniowego (wg indywidualnych potrzeb związanych np. z pracą inżynierską/naukową/zawodową). Wzory są numerowane, tablice są numerowane i podpisane nad tablicą, rysunki są numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi być wyczerpujący (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmieniać parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Kolejne sekcje sprawozdania są uzupełniane wg wymagań w opisie Projektu 2. i Harmonogramie Zajęć na WIKAMP KSR jako efekty zadań w poszczególnych tygodniach.

1 Cel

Celem projektu jest implementacja aplikacji desktopowej w technologii JDK (Java 25 LTS) generującej *lingwistyczne podsumowania* relacyjnej bazy danych w formie zdań języka quasi-naturalnego. Aplikacja udostępnia graficzny interfejs użytkownika, który dla użytkownika niezaawansowanego pozwala wygenerować podsumowania na podstawie predefiniowanych sumaryzatorów, kwalifikatorów i kwantyfikatorów (np. „samochody tanie i stare”), zdefiniować wagi w_i dla miar jakości, posortować podsumowania według wybranej miary i zapisać wybrane wyniki do pliku tekstowego, a dla użytkownika zaawansowanego dodatkowo zdefiniować nowe etykiety i funkcje przynależności.

Aplikacja generuje dwa rodzaje podsumowań:

- **jednopodmiotowe** – w pierwszej formie postaci „ Q obiektów ze zbioru ma własność S ” i drugiej formie postaci „ Q obiektów ze zbioru będących W ma własność S ”;
- **wielopodmiotowe** – we wszystkich czterech formach (I–IV.), porównujących dwa rozłączne podmioty P_1, P_2 ze zbioru (np. dwie różne marki samochodów),

gdzie Q jest *kwantyfikatorem lingwistycznym* (np. „większość”, „około połowy”), a S i W są *sumaryzatorami* (kwalifikatorami) zbudowanymi z etykiet zmiennych lingwistycznych powiązanych z atrybutami bazy – prostymi lub złożonymi za pomocą spójników logicznych. Dla każdego wygenerowanego podsumowania aplikacja wyznacza miary jakości od T_1 do T_{11} oraz miarę podsumowania optymalnego, na podstawie których zwracane są uporządkowane rankingi podsumowań.

Aplikacja obsługuje trzy rodziny funkcji przynależności: trójkątną, trapezoidalną i gaussowską. Dla wszystkich zmiennych lingwistycznych i kwantyfikatorów w sprawozdaniu wybrano funkcje **trapezoidalne** – mają one prostą czteroparametrową definicję, pozwalają w naturalny sposób uczynić skrajne etykiety lewo- i prawo-otwartymi oraz łatwo zapewnić rozmyte pokrycie zupełne uniwersum (sąsiednie etykiety nakładają się tak, że suma ich stopni przynależności wynosi 1).

Eksperymenty są prowadzone na podzbiorze 23 441 rekordów ze zbioru *Car Specification Dataset 1945–2020* (Kaggle, [8]), gromadzącego dane techniczne wersji wyposażenia samochodów osobowych z lat 1945–2020. Z oryginalnej bazy wybrano 12 atrybutów numerycznych (rozmywanych do zmiennych lingwistycznych) oraz 3 atrybuty nominalne (klucz, marka, model). Po odfiltrowaniu rekordów z brakującymi wartościami otrzymano spójny zbiór wszystkich rekordów tego samego typu, do którego zastosowanie narzędzi logiki rozmytej daje konkretne, zrozumiałe wnioski o całej populacji aut.

Spodziewanym efektem jest zbiór rankingów podsumowań posortowanych według miar jakości oraz wskazanie, które z miar T_1 – T_{11} niosą największą informację o badanej populacji aut, a także które kombinacje sumaryzatorów i kwantyfikatorów dają wartościowe (a które trywialne lub mylące) opisy zawartości bazy.

2 Baza danych, zmienne lingwistyczne, kwantyfikatory lingwistyczne

2.1 Charakterystyka podsumowywanej bazy danych

Wykorzystany zbiór *Car Specification Dataset 1945–2020* [8] zawiera 70 823 rekordów wersji wyposażenia samochodów osobowych (*trim level*) z 255 marek, wyprodukowanych w latach 1945–2020, opisanych 78 atrybutami; zbiór jest dostępny publicznie w serwisie Kaggle. Każdy rekord opisuje pojedynczą wersję wyposażenia jednego modelu, charakteryzując ją zestawem cech technicznych

(wymiały, masa, parametry silnika, osiągi, zużycie paliwa, geometria podwozia). Tego rodzaju dane są w motoryzacji rutynowo opisywane językiem naturalnym – klient czy dziennikarz motoryzacyjny mówi raczej o „mocnym silniku”, „dużym SUV-ie” albo „paliwożernym aucie” niż o konkretnych wartościach liczbowych 312 KM, 5 300 mm czy 11,3 l/100 km. Z tego powodu zbiór dobrze nadaje się do podsumowywania metodami logiki rozmytej – pozwala automatycznie generować zdania, które są intuicyjne dla człowieka, a trudne do uzyskania zwykłymi zapytaniami SQL.

Wybór atrybutów i filtracja. Z 78 oryginalnych kolumn wybrano **12 atrybutów numerycznych** podlegających rozmywaniu (są to atrybuty mierzalne, każdy z wieloma setkami unikalnych wartości) oraz **3 atrybuty nominalne** pełniące funkcję klucza i etykiet podmiotów w podsumowaniach wielopodmiotowych. Z bazy odrzucono rekordy, w których przynajmniej jedna z 15 wybranych kolumn miała wartość pustą. Wynikowy zbiór roboczy liczy **23 441 rekordów tego samego typu** (z 88 marek), co spełnia wymóg minimum 10 000 rekordów w projekcie. Pełną listę atrybutów wraz z jednostkami i empirycznymi zakresami przedstawia tabela 1.

Tabela 1: Lista 15 atrybutów wybranych ze zbioru *Car Specification Dataset 1945–2020* [8]: 12 numerycznych podlegających rozmyciu (zmienne lingwistyczne) oraz 3 nominalne wykorzystywane jako klucz/podmiot. Kolumna „zakres” podaje zaobserwowane minimum i maksimum w roboczym podzbiorze 23 441 rekordów.

Atrybut (kolumna CSV)	Opis	Jednostka	Zakres
<i>Atrybuty nominalne (klucz/podmiot):</i>			
id_trim	Identyfikator wersji wyposażenia	—	—
Make	Marka pojazdu	—	88 marek
Model	Model pojazdu	—	—
<i>Atrybuty numeryczne (zmienne lingwistyczne):</i>			
length_mm	Długość całkowita pojazdu	mm	1 826 – 6 165
wheelbase_mm	Rozstaw osi	mm	1 397 – 3 872
curb_weight_kg	Masa własna pojazdu	kg	625 – 3 000
minimum_trunk_capacity_l	Pojemność bagażnika	l	11 – 4 400
maximum_torque_n_m	Maksymalny moment obrotowy	Nm	44 – 1 017
capacity_cm3	Pojemność skokowa silnika	cm ³	599 – 7 443
engine_hp	Moc silnika	KM	29 – 710
turning_circle_m	Średnica zawracania	m	5,9 – 19,5
mixed_fuel_consumption_per_100_km_l	Spalanie mieszane	l/100 km	1,4 – 36,5
fuel_tank_capacity_l	Pojemność zbiornika paliwa	l	10 – 159
acceleration_0_100_km/h_s	Czas przyspieszenia 0–100 km/h	s	2,7 – 33,2
max_speed_km_per_h	Prędkość maksymalna	km/h	100 – 348

Aby spełnić wymóg projektu dotyczący dostępu przez DBMS, przefiltrowane dane są ładowane do pliku bazy **SQLite** (**cars.db**) jako pojedyncza tabela **cars** i odczytywane przez aplikację Javową przez sterownik **JDBC**. **SQLite** to w pełni relacyjny, plikowy system zarządzania bazą danych – nie wymaga osobnego serwera, ale obsługuje **SQL** i transakcje dokładnie tak jak duże silniki (**PostgreSQL**, **MySQL**). Fragment zawartości tabeli po wczytaniu przedstawia tabela 2.

Tabela 2: Fragment podzbioru roboczego (5 z 23 441 rekordów). Kolumny zostały skrócone do najważniejszych atrybutów dla zachowania czytelności; pełny zestaw 15 atrybutów – tabela 1. Wartości przepisane bez modyfikacji ze zbioru źródłowego.

Make	Model	dł. [mm]	masa [kg]	poj. [cm ³]	moc [KM]	0–100 [s]	$V_{\max}$ [km/h]	sp. [l]
BMW	320i	4 624	1 495	1 998	184	7,3	235	5,9
Volkswagen	Golf VII	4 255	1 205	1 395	122	9,1	203	4,9
Ford	Fiesta VI	3 950	1 041	1 242	82	13,3	168	5,1
Mercedes-Benz	S 500	5 246	2 065	4 663	455	4,8	250	9,1
Toyota	Aygo II	3 455	840	998	72	14,2	160	4,1

2.2 Zmienne lingwistyczne (atrybuty/własności obiektów)

Każdy z 12 atrybutów numerycznych potraktowano jako **zmienną lingwistyczną**, czyli atrybut, którego wartości można opisywać słowami z języka naturalnego zamiast surowych liczb – np. zamiast „300 KM” mówimy „silnik dynamiczny”. Dla każdej zmiennej trzeba ustalić trzy rzeczy:

- **przestrzeń rozważań** X – zakres wartości liczbowych atrybutu wyrażony w jego naturalnej jednostce (np. dla mocy silnika $X = [0, 800]$ KM);
- **zestaw etykiet** – słowa, którymi opisujemy wartości z X (np. „anemiczny / słaby / przyzwoity / dynamiczny / wyczynowy”);
- **funkcję przynależności** $\mu(x) \in [0, 1]$ dla każdej etykiety – mówi ona, w jakim stopniu konkretna wartość liczbową x pasuje do danej etykiety (1 = w pełni, 0 = w ogóle).

Konwencja etykiet. Dla każdej z 12 zmiennych przyjęto **pięcioelementowy** zbiór etykiet $\mathcal{T}$ uporządkowany według rosnącej wartości atrybutu, lecz *dobrany indywidualnie* do zmiennej z naturalnego, polskiego słownictwa motoryzacyjnego – pozwala to uniknąć monotonnego „bardzo mała / mała / średnia / duża / bardzo duża” i nadać każdej zmiennej własny, czytelny dla człowieka charakter (np. masa: „piórkowy – masywny”; moc: „anemiczny – wyczynowy”; spalanie: „oszczędny – rozrzutny”). Pełną listę etykiet dla każdej zmiennej zawierają tabele 3–14 w kolejnych podpunktach. Pięcioelementowy zestaw daje wystarczająco bogatą semantykę dla podsumowań kolejnych tygodni (zarówno jedno-, jak i wielopodmiotowych) przy zachowaniu czytelności wykresów; ujednolicenie liczby etykiet we wszystkich zmiennych ułatwia konstruowanie sumarytorów złożonych i porównywanie miar jakości między zmiennymi.

Funkcje przynależności. We wszystkich 12 zmiennych lingwistycznych i we wszystkich kwantyfikacjach (§2.3) używamy **funkcji trapezoidalnej** – ma

cztery parametry $a \leq b \leq c \leq d$ i postać:

$$\mu_{(a,b,c,d)}(x) = \begin{cases} 0, & x \leq a \text{ lub } x \geq d, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & b \leq x \leq c, \\ \frac{d-x}{d-c}, & c < x < d. \end{cases} \quad (1)$$

Pierwsza i ostatnia etykieta każdej zmiennej (np. „piórkowy” i „masywny” dla masy) są odpowiednio *lewo-* i *prawo-otwarte*: dla pierwszej przyjęto $a = b = x_{\min}$, a dla ostatniej $c = d = x_{\max}$ – dzięki temu zakres jest w całości pokryty (skrajne wartości należą do odpowiednio pierwszej lub ostatniej etykiety w stopniu 1). Sąsiednie trapezy są tak dobrane, że się ze sobą nakładają – dla każdej wartości x suma stopni przynależności do wszystkich pięciu etykiet wynosi w przybliżeniu 1, a w punkcie przejścia między sąsiednimi etykietami obie mają stopień 0,5 (przykład: rys. 7).


Dobór parametrów. Wartości parametrów (a, b, c, d) dla każdej z 5 etykiet wszystkich 12 zmiennych zebranych w tabelach 3–14 dobraliśmy w ten sam sposób: tak, żeby pasowały zarówno do faktycznego rozkładu danych w zbiorze (kwantyle 5 %, 25 %, 50 %, 75 %, 95 %), jak i do ogólnych zasad obowiązujących w motoryzacji. W podpisach tabel informacja ta nie jest powtarzana.

W kolejnych podpunktach dla każdej zmiennej podano: przestrzeń rozważań X , tabelę parametrów (a, b, c, d) wszystkich pięciu etykiet oraz wykres funkcji przynależności (linią ciągłą) wraz z obszarem wsparcia (odpowiadający kolorystycznie wypełnione obszary). Dla zaoszczędzenia miejsca opis każdej zmiennej zajmuje pojedynczą tabelę i pojedynczy rysunek.

2.2.1 Długość pojazdu (`length_mm`), $X = [1500, 6500]$ mm

Tabela 3: Parametry trapezowych funkcji przynależności dla zmiennej lingwistycznej „długość pojazdu”.

Etykieta	a	b	c	d
krótki	1 500	1 500	3 500	3 900
kompaktowy	3 500	3 900	4 200	4 500
standardowy	4 200	4 500	4 700	4 900
długi	4 700	4 900	5 100	5 300
wielkogabarytowy	5 100	5 300	6 500	6 500




Rysunek 1: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „długość pojazdu” $L \in [1500, 6500]$ mm. Granice etykiet odpowiadają segmentom Euro: A ($<3,7$ m), B ($3,7\text{--}4,5$ m), C/D ($4,5\text{--}4,9$ m), E ($4,9\text{--}5,3$ m), F ($>5,3$ m).

2.2.2 Rozstaw osi (wheelbase_mm), $X = [1300, 4000]$ mm

Tabela 4: Parametry trapezowych funkcji przynależności dla zmiennej „rozstaw osi”.

Etykieta	a	b	c	d
zwarty	1 300	1 300	2 300	2 450
krótki	2 300	2 450	2 550	2 650
standardowy	2 550	2 650	2 750	2 850
wydłużony	2 750	2 850	2 950	3 050
limuzynowy	2 950	3 050	4 000	4 000




Rysunek 2: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „rozstaw osi” $W \in [1300, 4000]$ mm.

2.2.3 Masa własna (curb_weight_kg), $X = [500, 3500]$ kg

Tabela 5: Parametry trapezowych funkcji przynależności dla zmiennej „masa własna”.

Etykieta	a	b	c	d
piórkowy	500	500	900	1 100
lekki	900	1 100	1 250	1 400
średnio ciężki	1 250	1 400	1 500	1 650
ciężki	1 500	1 650	1 850	2 050
masywny	1 850	2 050	3 500	3 500




Rysunek 3: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „masa własna pojazdu” $M \in [500, 3500]$ kg.

2.2.4 Pojemność bagażnika (minimum_trunk_capacity_l), $X = [0, 1500]$ l

Tabela 6: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność bagażnika”. Górna granica uniwersum ograniczona do 1500 l (rzadkie vany cargo z >3000 l są wciąż poprawnie sklasyfikowane jako „ładunkowy”).

Etykieta	a	b	c	d
symboliczny	0	0	200	300
ciasny	200	300	350	400
standardowy	350	400	450	500
pojemny	450	500	600	700
ładunkowy	600	700	1 500	1 500




Rysunek 4: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „pojemność bagażnika” $B \in [0, 1500]$ l.

2.2.5 Moment obrotowy (maximum_torque_n_m), $X = [0, 1100]$ Nm

Tabela 7: Parametry trapezowych funkcji przynależności dla zmiennej „maksymalny moment obrotowy silnika”.

Etykieta	a	b	c	d
wiotki	0	0	100	150
miękki	100	150	180	230
zrównoważony	180	230	280	350
mocarny	280	350	450	550
potężny	450	550	1 100	1 100




Rysunek 5: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „maksymalny moment obrotowy” $T \in [0, 1100]$ Nm.

2.2.6 Pojemność skokowa silnika (capacity_cm3), $X = [400, 8000] \text{ cm}^3$

Tabela 8: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność skokowa”.

Etykieta	a	b	c	d
miniaturowy	400	400	1 200	1 400
małolitrażowy	1 200	1 400	1 600	1 800
średniolitrażowy	1 600	1 800	2 000	2 500
wielkolitrażowy	2 000	2 500	3 500	4 500
gigantyczny	3 500	4 500	8 000	8 000




Rysunek 6: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „pojemność skokowa silnika” $V \in [400, 8000] \text{ cm}^3$.

2.2.7 Moc silnika (engine_hp), $X = [0, 800] \text{ KM}$

Tabela 9: Parametry trapezowych funkcji przynależności dla zmiennej „moc silnika”.

Etykieta	a	b	c	d
anemiczny	0	0	70	100
słaby	70	100	120	150
przyzwoity	120	150	180	220
dynamiczny	180	220	300	400
wyczynowy	300	400	800	800




Rysunek 7: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „moc silnika” $P \in [0, 800]$ KM. Zauważalne liniowe przejścia w punktach 50 %-stopnia przynależności (np. dla $P = 100$ KM: $\mu_{\text{anemiczny}}(P) = \mu_{\text{słaby}}(P) = 0,5$) ilustrują rozmyte pokrycie zupełne wymagane konstrukcją trapezów.

2.2.8 Średnica zawracania (turning_circle_m), $X = [5, 20]$ m

Tabela 10: Parametry trapezowych funkcji przynależności dla zmiennej „średnica zawracania”.

Etykieta	a	b	c	d
zwinny	5,0	5,0	9,5	10,0
zwrotny	9,5	10,0	10,5	11,0
przeciętny	10,5	11,0	11,3	11,7
nieporęczny	11,3	11,7	12,5	13,5
ociężały	12,5	13,5	20,0	20,0




Rysunek 8: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „średnica zawracania” $R \in [5, 20]$ m.

2.2.9 Spalanie mieszane (mixed_fuel_consumption_per_100_km_1), $X = [0, 25]$ l/100 km

Tabela 11: Parametry trapezowych funkcji przynależności dla zmiennej „spalanie mieszane”.

Etykieta	a	b	c	d
oszczędny	0	0	4	5
ekonomiczny	4	5	6	7
umiarkowany	6	7	8	10
paliwożerny	8	10	12	15
rozrzutny	12	15	25	25




Rysunek 9: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „spalanie mieszane” $F \in [0, 25]$ l/100 km.

2.2.10 Pojemność zbiornika paliwa (fuel_tank_capacity_1), $X = [10, 160]$ l

Tabela 12: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność zbiornika paliwa”.

Etykieta	a	b	c	d
mały	10	10	40	45
niewielki	40	45	50	55
standardowy	50	55	65	70
pojemny	65	70	80	90
ogromny	80	90	160	160




Rysunek 10: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „pojemność zbiornika paliwa” $J \in [10, 160]$ l.

2.2.11 Czas przyspieszenia 0–100 km/h (acceleration_0_100_kmh_s), $X = [2, 25]$ s

Tabela 13: Parametry trapezowych funkcji przynależności dla zmiennej „czas przyspieszenia 0–100 km/h”. Etykiety opisują samochód poprzez jego dynamikę: niska wartość czasu odpowiada autu „raketowemu”, wysoka – „ślamazarnemu”.

Etykieta	a	b	c	d
raketowy	2	2	5	6
szybki	5	6	8	9
przeciętny	8	9	11	13
ospały	11	13	15	17
ślamazarny	15	17	25	25




Rysunek 11: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „czas przyspieszenia 0–100 km/h” $A \in [2, 25]$ s. Niskie wartości A (< 5 s) odpowiadają samochodom szybkim, wysokie (> 15 s) – samochodom wolnym.

2.2.12 Prędkość maksymalna (max_speed_km_per_h), $X = [80, 360]$ km/h

Tabela 14: Parametry trapezowych funkcji przynależności dla zmiennej „prędkość maksymalna”.

Etykieta	a	b	c	d
powolny	80	80	150	165
miejski	150	165	180	195
autostradowy	180	195	210	230
wyścigowy	210	230	250	280
błyskawiczny	250	280	360	360



Rysunek 12: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „prędkość maksymalna” $S \in [80, 360]$ km/h.

2.3 Kwantyfikatory lingwistyczne (liczności obiektów)

Kwantyfikatory lingwistyczne to słowa, które w zdaniu „ Q obiektów ze zbioru ma własność S ” stoją w miejscu Q – np. „większość”, „około połowy”, „prawie wszystkie”. Każdy kwantyfikator opisujemy zbiorem rozmytym z trapezową funkcją przynależności, dokładnie tak samo jak zmienne lingwistyczne (§2.2), tylko że na innej dziedzinie. Rozróżniamy dwa rodzaje kwantyfikatorów:


- **względne (proporcjonalne)** – argumentem jest *udział* obiektów spełniających warunek, $r \in [0, 1]$ (np. „około połowy” = $r \approx 0,5$);
- **bezwzględne (absolutne)** – argumentem jest *liczba* obiektów spełniających warunek, $r \in \mathbb{N}$ (np. „kilka tysięcy” = $r \approx$ kilka tysięcy rekordów).

2.3.1 Kwantyfikatory względne

Przestrzeń rozważań $X_Q = [0, 1]$. Pięć etykiet pokrywa cały odcinek $[0, 1]$ z przejściami w okolicach typowych progów intuicji ($\sim 0,1$ – „prawie żaden”, $\sim 0,5$ – „około połowy”, $\sim 0,9$ – „prawie wszystkie”).

Tabela 15: Parametry trapezowych funkcji przynależności pięciu kwantyfikatorów względnych. Argumentem jest proporcja $r \in [0, 1]$ obiektów spełniających warunek.

Etykieta	a	b	c	d
prawie żaden	0,00	0,00	0,05	0,20
mniejszość	0,05	0,20	0,30	0,40
około połowy	0,30	0,40	0,60	0,70
większość	0,60	0,70	0,85	0,95
prawie wszystkie	0,85	0,95	1,00	1,00




Rysunek 13: Funkcje przynależności pięciu kwantyfikatorów względnych zdefiniowanych na przestrzeni $X_Q = [0, 1]$. Argumentem jest proporcja obiektów spełniających warunek (np. $r = 0,5$: $\mu_{\text{około połowy}} = 1$).

2.3.2 Kwantyfikatory bezwzględne

Przestrzeń rozważań $X_Q^{\text{abs}} = [0, 25\,000]$ – górna granica wzięta nieco powyżej liczności podzbioru roboczego (23 441 rekordów), aby etykieta „dużo” była aktywna dla niemal całej populacji bazy, gdy podsumowanie obejmuje praktycznie wszystkie rekordy. Przyjęto cztery etykiety zamiast pięciu, ponieważ na osi liczności (w przeciwieństwie do osi proporcji) różnice rzędu wielkości są bardziej istotne niż różnice o stałym kroku, a granice odpowiadają intuicji „bardzo mało / kilka tysięcy / kilkanaście tysięcy / dużo”.

Tabela 16: Parametry trapezowych funkcji przynależności czterech kwantyfikatorów bezwzględnych. Argumentem jest liczba (rekordów) obiektów spełniających warunek.

Etykieta	a	b	c	d
bardzo mało	0	0	1 000	3 000
kilka tysięcy	1 000	3 000	6 000	8 000
kilkanaście tysięcy	6 000	8 000	14 000	16 000
dużo	14 000	16 000	25 000	25 000




Rysunek 14: Funkcje przynależności czterech kwantyfikatorów bezwzględnych zdefiniowanych na przestrzeni $X_Q^{\text{abs}} = [0, 25\,000]$. Argumentem jest liczba obiektów spełniających warunek.

3 Narzędzia obliczeniowe: wybór/implementacja. Diagram UML klas do obliczeń rozmytych i generowania podsumowań

3.1 Źródło pakietu obliczeniowego

Pakiet obliczeń rozmytych ma charakter **hybrydowy**. Trzon – reprezentacja zbiorów rozmytych i ich własności, zmiennych lingwistycznych, kwantyfikatorów, sumaryzatorów/kwalifikatorów oraz podsumowań i ich miar jakości – jest *własną* implementacją, opartą o definicje z literatury przedmiotu ([4], [5], [6], [7], [3]; podsumowania wielopodmiotowe wg [9]). Jako składnik *zewnętrzny* użyto wyłącznie biblioteki `jFuzzyLogic` [10] – i to tylko do liczenia wartości trzech funkcji przynależności (trójkątnej, trapezoidalnej, gaussowskiej). Dostęp do danych realizuje sterownik `sqlite-jdbc` (relacyjna baza SQLite przez JDBC), a logowanie – SLF4J/Logback. Całość budowana jest narzędziem Maven; zależności pobierane są automatycznie (jFuzzyLogic z repozytorium JitPack).



Rysunek 15: Diagram klas UML pakietu obliczeń rozmytych i generowania podsumowań. Pakiety: **fuzzy.set** (zbiory i przestrzeń rozważań), **fuzzy.mf** (funkcje przynależności – delegacja do jFuzzyLogic), **fuzzy.linguistic** (zmienna lingwistyczna, etykieta, kwantyfikator), **summary** (sumaryzator/kwalifikator, podsumowania jednopodmiotowe), **summary.quality** (miary T_1 – T_{11}), **summary.multi** (podsumowania wielopodmiotowe, formy I–IV) oraz **data** (rekordy i dostęp do bazy). Linie ciągłe oznaczają złożenie (pole), przerywane – zależność użycia; trójkąt – realizację interfejsu.

3.2 Charakterystyka najważniejszych klas

Poniżej zwięzły opis klas i ich kluczowych metod (rys. 15).

Pakiet fuzzy.set – zbiory i przestrzeń rozważań. **Universe** reprezentuje przestrzeń rozważań w dwóch wariantach: gęstym (**continuous**, równomierne próbkowanie) i dyskretnym (**discrete**, co 1); metoda **samplePoints()** dostarcza punkty siatki do numerycznego liczenia własności. **FuzzySet** łączy nazwę, przestrzeń i funkcję przynależności; udostępnia własności wymagane w zadaniu – **height()**, **support()**, **alphaCut()**, **isNormal()**, **isEmpty()**, **isConvex()** – operacje teoriomnożościowe (**complement**, **union**, **intersect**) oraz względne licznosci nośnika i σ -count używane przez miary jakości. **ClassicSet** to odpowiednik zbioru klasycznego (twardy predykat 0/1) z tymi samymi operacjami. **Interval** (rekord) opisuje nośnik/ α -przekrój.

Pakiet `fuzzy.mf` – funkcje przynależności. Interfejs funkcyjny `MembershipFunction` ma jedną metodę `degree(x)`. Klasy `TriangularMf`, `TrapezoidalMf`, `GaussianMf` delegują obliczenie do `jFuzzyLogic` (z przycięciem wyniku do $[0, 1]$). `Operations` dostarcza dopełnienie, sumę (t-konorma maksimum) i iloczyn (t-norma minimum) jako dekoratory funkcji przynależności.

Pakiet `fuzzy.linguistic` – warstwa lingwistyczna. `LinguisticVariable` wiąże atrybut bazy z przestrzenią rozważań i zestawem etykiet; `degreeOf(label, x)` i `isValid(x)` obsługują przeliczanie i odrzucanie braków danych. `Label` (rekord) to nazwana etykieta nad zbiorem rozmytym. `Quantifier` reprezentuje kwantyfikator względny lub bezwzględny; `degree(quantity)` zwraca stopień dopasowania proporcji lub liczności.

Pakiet `summary` – podsumowania jednopodmiotowe. Interfejs `LabelExpression` (z implementacjami `Property` – pojedyncza etykieta, oraz `Connective` – złożenie spójnikiem AND/OR) reprezentuje sumaryzator lub kwalifikator i liczy stopień przynależności rekordu (`degree(rec)`). `SingleSubjectSummary` składa kwantyfikator, opcjonalny kwalifikator i sumaryzator w zdanie (`sentence()`) w pierwszej lub drugiej formie. `SummaryGenerator` produkuje zbiory kandydujących podsumowań na podstawie konfiguracji.

Pakiet `summary.quality` – miary jakości. `QualityMeasures.evaluate(...)` wyznacza w jednym przebiegu po rekordach komplet miar T_1 – T_{11} oraz wartość podsumowania optymalnego, zwracając rekord `Quality`. `QualityWeights` przechowuje znormalizowane wagi miar (sterowane z GUI) i liczy ważoną sumę.

Pakiet `summary.multi` – podsumowania wielopodmiotowe. `Subject` to nazwany predykat wyróżniający rozłączny podmiot (np. `ofMake` – jedna marka). `MultiSubjectSummary` reprezentuje cztery formy (I–IV) porównujące podmioty P_1 , P_2 , z fabrykami `formI` / `formII` / `formIII` / `formIV` i metodą `sentence()`. `MultiSubjectMeasures.degreeOfTruth(...)` liczy stopień prawdziwości T wg [9], a `MultiSubjectGenerator` generuje kandydatów dla zadanej pary podmiotów.

Pakiet `data` – dostęp do bazy. `CarRecord` (rekord) przechowuje wartości atrybutów jednego pojazdu. `DbImporter` ładuje przefiltrowany plik CSV do bazy SQLite, a `CarDataLoader` czyta rekordy przez JDBC; `Columns` centralizuje nazwy kolumn. `DataCleaner` to jednorazowe narzędzie selekcji kolumn i odrzucenia rekordów z brakami (przygotowanie zbioru roboczego).

3.3 Wymagania uruchomieniowe

Aplikacja wymaga **JDK/JRE w wersji 25 (Java 25 LTS)** – zgodnie z wymogiem „najnowsza wersja LTS” – oraz narzędzia **Apache Maven** do zbudowania i pobrania zależności. Baza danych nie wymaga osobnego serwera: SQLite

jest wbudowaną, plikową bazą relacyjną, a sterownik `sqlite-jdbc` zawiera natywne biblioteki dla głównych systemów (Windows, Linux, macOS). Pozostałe zależności (`jFuzzyLogic` przez `JitPack`, `SLF4J/Logback`) są pobierane automatycznie przy budowaniu. Uruchomienie części obliczeniowej następuje przez `mvn exec:java` (lub z zbudowanego pakietu); przy pierwszym starcie zbiór roboczy jest importowany z pliku CSV do bazy `cars.db`, a kolejne uruchomienia czytają już z bazy.

4 Jednopodmiotowe podsumowania lingwistyczne. Miary jakości, podsumowanie optymalne

Wyniki kolejnych eksperymentów wg punktów 2.-4. opisu projektu 2. Listy podsumowań jednopodmiotowych i tabele/rankingi podsumowań dla danych atrybutów obowiązkowe i dokładnie opisane w „captions” (tytułach), konieczny opis kolumn i wierszy tabel. Dla każdego podsumowania podane miary jakości oraz miara jakości podsumowania optymalnego. **Wzorów podsumowań ani miar nie należy przepisywać ani cytować, wystarczy podać literaturę, ale należy skomentować co oznaczają i jaką informacje niosą wybrane miary w wybranych przypadkach.**

Sekcja uzupełniona jako efekt zadania Tydzień 11 wg Harmonogramu Zajęć na WIKAMP KSR.

5 Wielopodmiotowe podsumowania lingwistyczne i ich miary jakości

Wyniki kolejnych eksperymentów wg punktów 2.-4. opisu projektu 2. Uzasadnienie i metoda podziału zbioru danych na rozłączne podmioty. Listy podsumowań wielopodmiotowych i tabele/rankingi podsumowań dla danych atrybutów obowiązkowe i dokładnie opisane w „captions” (tytułach), konieczny opis kolumn i wierszy tabel. **Wzorów podsumowań ani miar nie należy przepisywać ani cytować, wystarczy podać literaturę, ale należy skomentować co oznaczają i jaką informacje niosą wybrane miary w wybranych przypadkach.** Konieczne uwzględnienie wszystkich 4-ch form podsumowań wielopodmiotowych.

** Możliwe sformułowanie zagadnienia wielopodmiotowego podsumowania optymalnego **.

** Ewentualne wyniki realizacji punktu „na ocenę 5.0” wg opisu Projektu 2. i ich porównanie do wyników z części obowiązkowej **.

Sekcja uzupełniona jako efekt zadania Tydzień 12 wg Harmonogramu Zajęć na WIKAMP KSR.

6 Dyskusja, wnioski

We wnioskach z badania skomentować wyłącznie wpływ wybranych parametrów (zbiorów rozmytych, zmiennych lingwistycznych, miar podobieństwa, itp.) na jakość procesu klasyfikacji. Innymi słowy – wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury.

Komentować należy wyłącznie zbiór danych i zanczenie otrzymanych podsumowań. Metody nie komentujemy.

Dokładne interpretacje uzyskanych wyników w zależności od parametrów opisanych w punktach 3.-4 opisu Projektu 2. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: podsumowań i miar jakości). Ocena które podsumowania i dlaczego niosą najistotniejsze informacje i które ich miary jakości mają małe albo duże znaczenie dla wiarygodności i jakości otrzymanych agregacji/podsumowań.

Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje poziom zrozumienia rozwiązywanego problemu.

** Możliwości kontynuacji prac w obszarze logiki rozmytej i wnioskowania rozmytego, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadań Tydzień 11 i Tydzień 12 wg Harmonogramu Zajęć na WIKAMP KSR.

7 Braki w realizacji projektu 2.

Wymienić wg opisu Projektu 2. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

- [1] A. Niewiadomski, *Zbiory rozmyte typu 2. Zastosowania w reprezentowaniu informacji*, Seria „Problemy współczesnej informatyki” pod redakcją L. Rutkowskiego, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2019.
- [2] S. Zadrozny, *Zapytania nieprecyzyjne i lingwistyczne podsumowania baz danych*, EXIT, Warszawa, 2006.
- [3] A. Niewiadomski, *Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions*, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2008.

- [4] L. A. Zadeh, „The concept of a linguistic variable and its application to approximate reasoning”, *Information Sciences*, vol. 8, nr 3, ss. 199–249, 1975.
- [5] L. A. Zadeh, „A computational approach to fuzzy quantifiers in natural languages”, *Computers & Mathematics with Applications*, vol. 9, nr 1, ss. 149–184, 1983.
- [6] R. R. Yager, „A new approach to the summarization of data”, *Information Sciences*, vol. 28, nr 1, ss. 69–86, 1982.
- [7] J. Kacprzyk, R. R. Yager, „Linguistic summaries of data using fuzzy logic”, *International Journal of General Systems*, vol. 30, nr 2, ss. 133–154, 2001.
- [8] J. Islam, *Car Specification Dataset 1945–2020*, Kaggle, 2020.
<https://www.kaggle.com/datasets/jahaidulislam/car-specification-dataset-1945-2020>
- [9] A. Niewiadomski, I. Superson, „On multi-subjectivity in linguistic summarization of relational databases”, *Journal of Theoretical and Applied Computer Science*, vol. 8, nr 1, ss. 15–34, 2014.
- [10] P. Cingolani, J. Alcalá-Fdez, „jFuzzyLogic: a Java library to design fuzzy logic controllers according to the standard for fuzzy control programming”, *International Journal of Computational Intelligence Systems*, vol. 6, sup. 1, ss. 61–75, 2013.

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.