

Komputerowe systemy rozpoznawania 2024/2025

Projekt 2. Podsumowania lingwistyczne relacyjnych baz danych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr in. Marcin Kacprowicz

25 maja 2026

Opis projektu ma form artykułu naukowego lub raportu z zadania badawczego (dowiadczalnego/obliczeniowego (wg indywidualnych potrzeb związanych np. z prac inżyniersk/naukow/zawodow). Wzory s numerowane, tablice s numerowane i podpisane nad tablic, rysunki s numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi by wyczerpujcy (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmienia parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Kolejne sekcje sprawozdania są uzupełniane wg wymaga w opisie Projektu 2. i Harmonogramie Zaj na WIKAMP KSR jako efekty zada w poszczególnych tygodniach.

1 Cel

Celem projektu jest implementacja aplikacji desktopowej w technologii JDK (Java 25 LTS) generującej *lingwistyczne podsumowania* relacyjnej bazy danych w formie zda języka quasi-naturalnego. Aplikacja udostępnia graficzny interfejs użytkownika, który dla użytkownika niezaintensyfikowanego pozwala wygenerować podsumowania na podstawie predefiniowanych sumaryzatorów, kwalifikatorów i kwantyfikatorów (np. „samochody tanie i stare”), zdefiniować wagi w_i dla miar jakości, posortować podsumowania według wybranej miary i zapisać wybrane wyniki do pliku tekstowego, a dla użytkownika zaawansowanego dodatkowo zdefiniować nowe etykiety i funkcje przynależności.

Aplikacja generuje dwa rodzaje podsumowań:

- **jednopodmiotowe** – w pierwszej formie postaci „ Q obiektów ze zbioru S ” i drugiej formie postaci „ Q obiektów ze zbioru W ”

ma wasno S ”;

- **wielopodmiotowe** – we wszystkich czterech formach (I.–IV.), porównujących dwa rozczne podmioty P_1, P_2 ze zbioru (np. dwie różne marki samochodów),

gdzie Q jest *kwantyfikatorem lingwistycznym* (np. „wikszo”, „okoo poowy”), a S i W s *sumaryzatorami* (kwalifikatorami) zbudowanymi z etykiet zmiennych lingwistycznych powizanych z atrybutami bazy – prostymi lub zoonymi za pomoc spójników logicznych. Dla kadego wygenerowanego podsumowania aplikacja wyznacza miary jakoci od T_1 do T_{11} oraz miar podsumowania optymalnego, na podstawie których zwracane s uporzdkowane rankingi podsumowa.

Aplikacja obsuguje trzy rodziny funkcji przynalenoci: trójktn, trapezoidaln i gaussowsk. Dla wszystkich zmiennych lingwistycznych i kwantyfikatorów w sprawozdaniu wybrano funkcje **trapezoidalne** – maj one prost czteroparametrow definicj, pozwalaj w naturalny sposób uczyni skrajne etykiety lewo- i prawotwartymi oraz atwo zapewni rozmyte pokrycie zupene uniwersum (ssiednie etykiety nakadaj si tak, e suma ich stopni przynalenoci wynosi 1).

Eksperymenty s prowadzone na podzbiorze 23 441 rekordów ze zbioru *Car Specification Dataset 1945–2020* (Kaggle, [8]), gromadzcgo dane techniczne wersji wyposaenia samochodów osobowych z lat 1945–2020. Z oryginalnej bazy wybrano 12 atrybutów numerycznych (rozmywanych do zmiennych lingwistycznych) oraz 3 atrybuty nominalne (klucz, marka, model). Po odfiltrowaniu rekordów z brakujcymi wartociami otrzymano spójny zbiór wszystkich rekordów tego samego typu, do którego zastosowanie narzdzi logiki rozmytej daje konkretne, zrozumiae wnioski o caej populacji aut.

Spodziewanym efektem jest zbiór rankingów podsumowa posortowanych wedug miar jakoci oraz wskazanie, które z miar T_1 – T_{11} nios najwiksza informacj o badanej populacji aut, a take które kombinacje sumaryzatorów i kwantyfikatorów daj wartociowe (a które trywialne lub mylce) opisy zawartoci bazy.

2 Baza danych, zmienne lingwistyczne, kwantyfikatory lingwistyczne

2.1 Charakterystyka podsumowywanej bazy danych

Wykorzystany zbiór *Car Specification Dataset 1945–2020* [8] zawiera 70 823 rekordów wersji wyposaenia samochodów osobowych (*trim level*) z 255 marek, wyprodukowanych w latach 1945–2020, opisanych 78 atrybutami; zbiór jest dostpny publicznie w serwisie Kaggle. Kady rekord opisuje pojedyncz wersj wyposaenia jednego modelu, charakteryzujc j zestawem cech technicznych (wymiaary, masa, parametry silnika, osigi, zuycie paliwa, geometria podwozia). Tego rodzaju dane s w motoryzacji rutynowo opisywane jzykiem naturalnym – klient czy dziennikarz motoryzacyjny mówi raczej o „mocnym silniku”, „duym SUV-ie” albo „paliwoernym aucie” ni o konkretnych wartociach liczbowych 312 KM, 5 300 mm czy 11,3 l/100 km. Z tego powodu zbiór dobrze nadaje si do podsumowywania

metodami logiki rozmytej – pozwala automatycznie generować zdania, które są intuicyjne dla człowieka, a trudne do uzyskania zwykłymi zapytaniami SQL.

Wybór atrybutów i filtracja. Z 78 oryginalnych kolumn wybrano **12 atrybutów numerycznych** podlegających rozmywaniu (są to atrybuty mierzalne, każdy z wieloma setkami unikalnych wartości) oraz **3 atrybuty nominalne** pełniące funkcję klucza i etykiet podmiotów w podsumowaniach wielopodmiotowych. Z bazy odrzucono rekordy, w których przynajmniej jedna z 15 wybranych kolumn miała wartość pustą. Wynikowy zbiór roboczy liczy **23 441 rekordów tego samego typu** (z 88 marek), co spełnia wymóg minimum 10 000 rekordów w projekcie. Poniżej listę atrybutów wraz z jednostkami i empirycznymi zakresami przedstawia tabela 1.

Tabela 1: Lista 15 atrybutów wybranych ze zbioru *Car Specification Dataset 1945–2020* [8]: 12 numerycznych podlegających rozmyciu (zmienne lingwistyczne) oraz 3 nominalne wykorzystywane jako klucz/podmiot. Kolumna „zakres” podaje zaobserwowane minimum i maksimum w roboczym podzbiore 23 441 rekordów.

Atrybut (kolumna CSV)	Opis	Jednostka	Zakres
<i>Atrybuty nominalne (klucz/podmiot):</i>			
id_trim	Identyfikator wersji wyposażenia	—	—
Make	Marka pojazdu	—	88 marek
Model	Model pojazdu	—	—
<i>Atrybuty numeryczne (zmienne lingwistyczne):</i>			
length_mm	Długość całkowita pojazdu	mm	1 826 – 6 165
wheelbase_mm	Rozstaw osi	mm	1 397 – 3 872
curb_weight_kg	Masa własna pojazdu	kg	625 – 3 000
minimum_trunk_capacity_l	Pojemność bagażnika	l	11 – 4 400
maximum_torque_n_m	Maksymalny moment obrotowy	Nm	44 – 1 017
capacity_cm3	Pojemność skokowa silnika	cm ³	599 – 7 443
engine_hp	Moc silnika	KM	29 – 710
turning_circle_m	Rednica zawracania	m	5,9 – 19,5
mixed_fuel_consumption_per_100_km_l	Spalanie mieszane	l/100 km	1,4 – 36,5
fuel_tank_capacity_l	Pojemność zbiornika paliwa	l	10 – 159
acceleration_0_100_km/h_s	Czas przyspieszenia 0–100 km/h	s	2,7 – 33,2
max_speed_km_per_h	Prędkość maksymalna	km/h	100 – 348

Aby spełnić wymóg projektu dotyczący dostępu przez DBMS, przefiltrowane dane są załadowane do pliku bazy **SQLite** (`cars.db`) jako pojedyncza tabela `cars` i odczytywane przez aplikację Javę przez sterownik JDBC. SQLite to w pełni relacyjny, plikowy system zarządzania bazami danych – nie wymaga osobnego serwera, ale obsługuje SQL i transakcje dokładnie tak jak dwa silniki (PostgreSQL, MySQL). Fragment zawartości tabeli po wczytaniu przedstawia tabela 2.

Tabela 2: Fragment podzbioru roboczego (5 z 23 441 rekordów). Kolumny zostay skrócone do najwanniejszych atrybutów dla zachowania czytelności; peny zestaw 15 atrybutów – tabela 1. Wartoci przepisane bez modyfikacji ze zbioru ródowego.

Make	Model	d. [mm]	masa [kg]	poj. [cm ³]	moc [KM]	0–100 [s]	$V_{\max}$ [km/h]	sp. [l]
BMW	320i	4 624	1 495	1 998	184	7,3	235	5,9
Volkswagen	Golf VII	4 255	1 205	1 395	122	9,1	203	4,9
Ford	Fiesta VI	3 950	1 041	1 242	82	13,3	168	5,1
Mercedes-Benz	S 500	5 246	2 065	4 663	455	4,8	250	9,1
Toyota	Aygo II	3 455	840	998	72	14,2	160	4,1

2.2 Zmienne lingwistyczne (atrybuty/wasnoci obiektów)

Kady z 12 atrybutów numerycznych potraktowano jako **zmienn lingwistyczn**, czyli atrybut, którego wartoci mona opisywa sowami z jzyka naturalnego zamiast surowych liczb – np. zamiast „300 KM” mówimy „silnik dynamiczny”. Dla kadej zmiennej trzeba ustali trzy rzeczy:

- **przestrze rozwaa** X – zakres wartoci liczbowych atrybutu wyraony w jego naturalnej jednostce (np. dla mocy silnika $X = [0, 800]$ KM);
- **zestaw etykiet** – sowa, którymi opisujemy wartoci z X (np. „anemiczny / saby / przyzwoity / dynamiczny / wyczynowy”);
- **funkcj przynalenoci** $\mu(x) \in [0, 1]$ dla kadej etykiety – mówi ona, w jakim stopniu konkretna warto liczbowa x pasuje do danej etykiety (1 = w peni, 0 = w ogóle).

Konwencja etykiet. Dla kadej z 12 zmiennych przyjto **picioelementowy** zbiór etykiet $\mathcal{T}$ uporządkowany wedug rosnej wartoci atrybutu, lecz *dobrany indywidualnie* do zmiennej z naturalnego, polskiego sownictwa motoryzacyjnego – pozwala to unikn monotonnego „bardzo maa / maa / rednia / dua / bardzo dua” i nada kadej zmiennej wasny, czytelny dla czowieka charakter (np. masa: „piórkowy – masywny”; moc: „anemiczny – wyczynowy”; spalanie: „oszczdny – rozrzutny”). Pen list etykiet dla kadej zmiennej zawieraj tabele 3–14 w kolejnych podpunktach. Picioelementowy zestaw daje wystarczajco bogat semantyk dla podsumowa kolejnych tygodni (zarówno jedno-, jak i wielopodmiotowych) przy zachowaniu czytelności wykresów; ujednolicenie liczby etykiet we wszystkich zmiennych uatwia konstruowanie sumarytorów zoonych i porównywanie miar jakości midzy zmiennymi.

Funkcje przynalenoci. We wszystkich 12 zmiennych lingwistycznych i we wszystkich kwantyfikatorach (§2.3) uywamy **funkcji trapezoidalnej** – ma

cztery parametry $a \leq b \leq c \leq d$ i posta:

$$\mu_{(a,b,c,d)}(x) = \begin{cases} 0, & x \leq a \text{ lub } x \geq d, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & b \leq x \leq c, \\ \frac{d-x}{d-c}, & c < x < d. \end{cases} \quad (1)$$

Pierwsza i ostatnia etykieta kadej zmiennej (np. „piórkowy” i „masywny” dla masy) s odpowiednio *lewo-* i *prawo-otwarte*: dla pierwszej przyjto $a = b = x_{\min}$, a dla ostatniej $c = d = x_{\max}$ – dziki temu zakres jest w caoci pokryty (skrajne wartoci nale do odpowiednio pierwszej lub ostatniej etykiety w stopniu 1). Ssiednie trapezy s tak dobrane, e si ze sob nakadaj – dla kadej wartoci x suma stopni przynalenoci do wszystkich piciu etykiet wynosi w przyblieniu 1, a w punkcie przejcia midzy ssiednimi etykietami obie maj stopie 0,5 (przykad: rys. 7).


Dobór parametrów. Wartoci parametrów (a, b, c, d) dla kadej z 5 etykiet wszystkich 12 zmiennych zebranych w tabelach 3–14 dobralimy w ten sam sposób: tak, eby pasoway zarówno do faktycznego rozkadu danych w zbiorze (kwantyle 5 %, 25 %, 50 %, 75 %, 95 %), jak i do ogólnych zasad obowizujcych w motoryzacji. W podpisach tabel informacja ta nie jest powtarzana.

W kolejnych podpunktach dla kadej zmiennej podano: przestrze rozwa X , tabel parametrów (a, b, c, d) wszystkich piciu etykiet oraz wykres funkcji przynalenoci (lini cig) wraz z obszarem wsparcia (odpowiadajcy kolorystycznie wypenione obszary). Dla zaoszczdzenia miejsca opis kadej zmiennej zajmuje pojedyncz tabel i pojedynczy rysunek.

2.2.1 Dugo pojazdu (`length_mm`), $X = [1500, 6500]$ mm

Tabela 3: Parametry trapezowych funkcji przynalenoci dla zmiennej lingwistycznej „dugo pojazdu”.

Etykieta	a	b	c	d
krótki	1 500	1 500	3 500	3 900
kompaktowy	3 500	3 900	4 200	4 500
standardowy	4 200	4 500	4 700	4 900
dugi	4 700	4 900	5 100	5 300
wielkogabarytowy	5 100	5 300	6 500	6 500




Rysunek 1: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „długość pojazdu” $L \in [1500, 6500]$ mm. Granice etykiet odpowiadają segmentom Euro: A ($<3,7$ m), B ($3,7-4,5$ m), C/D ($4,5-4,9$ m), E ($4,9-5,3$ m), F ($>5,3$ m).

2.2.2 Rozstaw osi (wheelbase_mm), $X = [1300, 4000]$ mm

Tabela 4: Parametry trapezowych funkcji przynależności dla zmiennej „rozstaw osi”.

Etykieta	a	b	c	d
zwarty	1 300	1 300	2 300	2 450
krótki	2 300	2 450	2 550	2 650
standardowy	2 550	2 650	2 750	2 850
wyduony	2 750	2 850	2 950	3 050
limuzynowy	2 950	3 050	4 000	4 000




Rysunek 2: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „rozstaw osi” $W \in [1300, 4000]$ mm.

2.2.3 Masa wasna (curb_weight_kg), $X = [500, 3500]$ kg

Tabela 5: Parametry trapezowych funkcji przynalenoci dla zmiennej „masa wasna”.

Etykieta	a	b	c	d
piórkowy	500	500	900	1 100
lekki	900	1 100	1 250	1 400
rednio ciki	1 250	1 400	1 500	1 650
ciki	1 500	1 650	1 850	2 050
masywny	1 850	2 050	3 500	3 500




Rysunek 3: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „masa wasna pojazdu” $M \in [500, 3500]$ kg.

2.2.4 Pojemno baganika (minimum_trunk_capacity_l), $X = [0, 1500]$ l

Tabela 6: Parametry trapezowych funkcji przynalenoci dla zmiennej „pojemno baganika”. Górna granica uniwersum ograniczona do 1500 l (rzadkie vany cargo z >3000 l s wci poprawnie sklasyfikowane jako „adunkowy”).

Etykieta	a	b	c	d
symboliczny	0	0	200	300
ciasny	200	300	350	400
standardowy	350	400	450	500
pojemny	450	500	600	700
adunkowy	600	700	1 500	1 500




Rysunek 4: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „pojemno baganika” $B \in [0, 1500]$ l.

2.2.5 Moment obrotowy (`maximum_torque_n_m`), $X = [0, 1100]$ Nm

Tabela 7: Parametry trapezowych funkcji przynalenoci dla zmiennej „maksymalny moment obrotowy silnika”.

Etykieta	a	b	c	d
wiotki	0	0	100	150
mikki	100	150	180	230
zrównowaony	180	230	280	350
mocarny	280	350	450	550
potny	450	550	1 100	1 100




Rysunek 5: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „maksymalny moment obrotowy” $T \in [0, 1100]$ Nm.

2.2.6 Pojemno skokowa silnika (capacity_cm3), $X = [400, 8000] \text{ cm}^3$

Tabela 8: Parametry trapezowych funkcji przynalenoci dla zmiennej „pojemno skokowa”.

Etykieta	a	b	c	d
miniaturowy	400	400	1 200	1 400
maolitraowy	1 200	1 400	1 600	1 800
redniolitraowy	1 600	1 800	2 000	2 500
wielkolitraowy	2 000	2 500	3 500	4 500
gigantyczny	3 500	4 500	8 000	8 000




Rysunek 6: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „pojemno skokowa silnika” $V \in [400, 8000] \text{ cm}^3$.

2.2.7 Moc silnika (engine_hp), $X = [0, 800] \text{ KM}$

Tabela 9: Parametry trapezowych funkcji przynalenoci dla zmiennej „moc silnika”.

Etykieta	a	b	c	d
anemiczny	0	0	70	100
saby	70	100	120	150
przyzwoity	120	150	180	220
dynamiczny	180	220	300	400
wyczynowy	300	400	800	800




Rysunek 7: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „moc silnika” $P \in [0, 800]$ KM. Zauważalne liniowe przejścia w punktach 50 %-stopnia przynależności (np. dla $P = 100$ KM: $\mu_{\text{anemiczny}}(P) = \mu_{\text{słaby}}(P) = 0,5$) ilustrują rozmyte pokrycie zupełnie wymagane konstrukcją trapezów.

2.2.8 rednica zawracania (`turning_circle_m`), $X = [5, 20]$ m

Tabela 10: Parametry trapezowych funkcji przynależności dla zmiennej „rednica zawracania”.

Etykieta	a	b	c	d
zwinny	5,0	5,0	9,5	10,0
zwrotny	9,5	10,0	10,5	11,0
przeciętny	10,5	11,0	11,3	11,7
nieporęczny	11,3	11,7	12,5	13,5
ociężały	12,5	13,5	20,0	20,0




Rysunek 8: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „rednica zawracania” $R \in [5, 20]$ m.

2.2.9 Spalanie mieszane (`mixed_fuel_consumption_per_100_km_1`), $X = [0, 25]$ l/100 km

Tabela 11: Parametry trapezowych funkcji przynalenoci dla zmiennej „spalanie mieszane”.

Etykieta	a	b	c	d
oszczędny	0	0	4	5
ekonomiczny	4	5	6	7
umiarkowany	6	7	8	10
paliwoerny	8	10	12	15
rozrzutny	12	15	25	25




Rysunek 9: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „spalanie mieszane” $F \in [0, 25]$ l/100 km.

2.2.10 Pojemno zbiornika paliwa (`fuel_tank_capacity_1`), $X = [10, 160]$ l

Tabela 12: Parametry trapezowych funkcji przynalenoci dla zmiennej „pojemno zbiornika paliwa”.

Etykieta	a	b	c	d
may	10	10	40	45
niewielki	40	45	50	55
standardowy	50	55	65	70
pojemny	65	70	80	90
ogromny	80	90	160	160




Rysunek 10: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „pojemność zbiornika paliwa” $J \in [10, 160]$ l.

2.2.11 Czas przyspieszenia 0–100 km/h (`acceleration_0_100_kmh_s`), $X = [2, 25]$ s

Tabela 13: Parametry trapezowych funkcji przynależności dla zmiennej „czas przyspieszenia 0–100 km/h”. Etykiety opisują samochód poprzez jego dynamik: niska wartość czasu odpowiada autu „raketowemu”, wysoka – „lamazarnemu”.

Etykieta	a	b	c	d
raketowy	2	2	5	6
szybki	5	6	8	9
przeciętny	8	9	11	13
ospały	11	13	15	17
ślamazarny	15	17	25	25




Rysunek 11: Funkcje przynależności pięciu etykiet zmiennej lingwistycznej „czas przyspieszenia 0–100 km/h” $A \in [2, 25]$ s. Niskie wartości A (< 5 s) odpowiadają samochodom szybkim, wysokie (> 15 s) – samochodom wolnym.

2.2.12 Prdko maksymalna (`max_speed_km_per_h`), $X = [80, 360]$ km/h

Tabela 14: Parametry trapezowych funkcji przynalenoci dla zmiennej „prdko maksymalna”.

Etykieta	a	b	c	d
powolny	80	80	150	165
miejski	150	165	180	195
autostradowy	180	195	210	230
wycigowy	210	230	250	280
byskawiczny	250	280	360	360



Rysunek 12: Funkcje przynalenoci piciu etykiet zmiennej lingwistycznej „prdko maksymalna” $S \in [80, 360]$ km/h.

2.3 Kwantyfikatory lingwistyczne (licznoci obiektów)

Kwantyfikatory lingwistyczne to sowa, które w zdaniu „ Q obiektów ze zbioru ma wasno S ” stoj w miejscu Q – np. „wikszo”, „okoo poowy”, „prawie wszystkie”. Kady kwantyfikator opisujemy zbiorem rozmytym z trapezow funkcj przynalenoci, dokadnie tak samo jak zmienne lingwistyczne (§2.2), tylko e na innej dziedzinie. Rozróniamy dwa rodzaje kwantyfikatorów:


- **wzglndne (proporcjonalne)** – argumentem jest *udzia* obiektów speniaj-cych warunek, $r \in [0, 1]$ (np. „okoo poowy” = $r \approx 0,5$);
- **bezwzglndne (absolutne)** – argumentem jest *liczba* obiektów speniaj-cych warunek, $r \in \mathbb{N}$ (np. „kilka tysicy” = $r \approx$ kilka tysicy rekordów).

2.3.1 Kwantyfikatory wzglndne

Przestrze rozwaaa $X_Q = [0, 1]$. Pi etykiet pokrywa cay odcinek $[0, 1]$ z przejcciami w okolicach typowych progów intuicji ($\sim 0,1$ – „prawie aden”, $\sim 0,5$ – „okoo poowy”, $\sim 0,9$ – „prawie wszystkie”).

Tabela 15: Parametry trapezowych funkcji przynależności pięciu kwantyfikatorów względnych. Argumentem jest proporcja $r \in [0, 1]$ obiektów spełniających warunek.

Etykieta	a	b	c	d
prawie aden	0,00	0,00	0,05	0,20
mniejszo	0,05	0,20	0,30	0,40
około połowy	0,30	0,40	0,60	0,70
wiekszo	0,60	0,70	0,85	0,95
prawie wszystkie	0,85	0,95	1,00	1,00




Rysunek 13: Funkcje przynależności pięciu kwantyfikatorów względnych zdefiniowanych na przestrzeni $X_Q = [0, 1]$. Argumentem jest proporcja obiektów spełniających warunek (np. $r = 0,5$: $\mu_{\text{około połowy}} = 1$).

2.3.2 Kwantyfikatory bezwzględne

Przestrze rozwiązań $X_Q^{\text{abs}} = [0, 25\,000]$ – górna granica wzięta nieco powyżej liczności podzbioru roboczego (23 441 rekordów), aby etykieta „duo” była aktywna dla niemal całej populacji bazy, gdy podsumowanie obejmuje praktycznie wszystkie rekordy. Przyjeto cztery etykiety zamiast pięciu, ponieważ na osi licznoci (w przeciwieństwie do osi proporcji) różnice rzędu wielkości są bardziej istotne niż różnice o stałym kroku, a granice odpowiadają intuicji „bardzo mało / kilka tysięcy / kilkanaście tysięcy / duo”.

Tabela 16: Parametry trapezowych funkcji przynależności czterech kwantyfikatorów bezwzględnych. Argumentem jest liczba (rekordów) obiektów spełniających warunek.

Etykieta	a	b	c	d
bardzo mało	0	0	1 000	3 000
kilka tysięcy	1 000	3 000	6 000	8 000
kilkaście tysięcy	6 000	8 000	14 000	16 000
duo	14 000	16 000	25 000	25 000




Rysunek 14: Funkcje przynależności czterech kwantyfikatorów bezwzględnych zdefiniowanych na przestrzeni $X_Q^{\text{abs}} = [0, 25\,000]$. Argumentem jest liczba obiektów spełniających warunek.

3 Narzędzia obliczeniowe: wybór/implementacja. Diagram UML klas do oblicze rozmytych i generowania podsumowa

3.1 ródło pakietu obliczeniowego

Pakiet oblicze rozmytych ma charakter **hybrydowy**. Trzon – reprezentacja zbiorów rozmytych i ich własności, zmiennych lingwistycznych, kwantyfikatorów, sumaryzatorów/kwalifikatorów oraz podsumowa i ich miar jakości – jest *wasną* implementacją, opartą o definicje z literatury przedmiotu ([4], [5], [6], [7], [3]; podsumowania wielopodmiotowe wg [9]). Jako składowy *zewnątrzny* użyto wyciągu biblioteki `jFuzzyLogic` [10] – i to tylko do liczenia wartości trzech funkcji przynależności (trójkątnej, trapezoidalnej, gaussowskiej). Dostęp do danych realizuje sterownik `sqlite-jdbc` (relacyjna baza SQLite przez JDBC), a logowanie – SLF4J/Logback. Całość budowana jest narzędziem Maven; zależności pobierane są automatycznie (`jFuzzyLogic` z repozytorium JitPack).



Rysunek 15: Diagram klas UML pakietu oblicze rozmytych i generowania podsumowa. W kadej klasie wyróniono sekcj pól (atrybutów) – nad lini – oraz kluczowych operacji (metod); zagniedone typy wyliczeniowe (np. `Universe.Kind`, `Quantifier.Type`, `MultiSubjectSummary.Form`) pokazano jako odrbne elementy powizane z klas macierzyst. Pakiety: **fuzzy.set** (zbiory i przestrze rozwa), **fuzzy.mf** (funkcje przynalenoci – delegacja do `jFuzzyLogic`), **fuzzy.linguistic** (zmienna lingwistyczna, etykieta, kwantyfikator), **summary** (sumaryzator/kwalifikator, podsumowania jednopodmiotowe), **summary.quality** (miary T_1 – T_{11}), **summary.multi** (podsumowania wielopodmiotowe, formy I–IV) oraz **data** (rekordy i dostp do bazy). Linie cige oznaczaj zoenie (pole), przerywane – zaleno uycia; trójkrt – realizacj interfejsu.

3.2 Charakterystyka najwaniejszych klas

Poniej zwizy opis klas, ich pól oraz kluczowych metod (rys. 15).

Pakiet `fuzzy.set` – zbiory i przestrze rozwaa. `Universe` reprezentuje przestrze rozwaa w dwóch wariantach: `gstym` (`continuous`, równomierne próbkowanie) i dyskretnym (`discrete`, co 1); metoda `samplePoints()` dostarcza punkty siatki do numerycznego liczenia wasnoci. `FuzzySet` czy nazw, przestrze i funkcj przynalenoci; udostpnia wasnoci wymagane w zadaniu – `height()`, `support()`, `alphaCut()`, `isNormal()`, `isEmpty()`, `isConvex()` – operacje teoriomnogociowe (`complement`, `union`, `intersect`) oraz wzgldne licznoci nonika i σ -count uywane przez miary jakoci. `ClassicSet` to odpowiednik zbioru klasycznego (twardy predykat 0/1) z tymi samymi operacjami. `Interval` (rekord) opisuje nonik/ α -przekrój.

Pakiet `fuzzy.mf` – funkcje przynalenoci. Interfejs funkcyjny `MembershipFunction` ma jedn metod `degree(x)`. Klasy `TriangularMf`, `TrapezoidalMf`, `GaussianMf` deleguj obliczenie do `jFuzzyLogic` (z przyciciem wyniku do $[0, 1]$). `Operations` dostarcza dopenienie, `sum` (t-konorma maksimum) i iloczyn (t-norma minimum) jako dekoratory funkcji przynalenoci.

Pakiet `fuzzy.linguistic` – warstwa lingwistyczna. `LinguisticVariable` wie atrybut bazy z przestrzeni rozwaa i zestawem etykiet; `degreeOf(label, x)` i `isValid(x)` obsuguj przeliczanie i odrzucanie braków danych. `Label` (rekord) to nazwana etykieta nad zbiorem rozmytym. `Quantifier` reprezentuje kwantyfikator wzgldny lub bezwzgdny; `degree(quantity)` zwraca stopie dopasowania proporcji lub licznoci.

Pakiet `summary` – podsumowania jednopodmiotowe. Interfejs `LabelExpression` (z implementacjami `Property` – pojedyncza etykieta, oraz `Connective` – zoenie spójnikiem AND/OR) reprezentuje sumaryzator lub kwalifikator i liczy stopie przynalenoci rekordu (`degree(rec)`). `SingleSubjectSummary` skada kwantyfikikator, opcjonalny kwalifikator i sumaryzator w zdanie (`sentence()`) w pierwszej lub drugiej formie. `SummaryGenerator` produkuje zbiory kandydujących podsumowa na podstawie konfiguracji.

Pakiet `summary.quality` – miary jakoci. `QualityMeasures.evaluate(...)` wyznacza w jednym przebiegu po rekordach komplet miar T_1 – T_{11} oraz warto podsumowania optymalnego, zwracając rekord `Quality`. `QualityWeights` przechowuje znormalizowane wagi miar (sterowane z GUI) i liczy waon sum.

Pakiet `summary.multi` – podsumowania wielopodmiotowe. `Subject` to nazwany predykat wyróżniający rozczny podmiot (np. `ofMake` – jedna marka). `MultiSubjectSummary` reprezentuje cztery formy (I–IV) porównujące podmioty P_1 , P_2 , z fabrykami `formI`/`formII`/`formIII`/`formIV` i metod `sentence()`.

`MultiSubjectMeasures.degreeOfTruth(...)` liczy stopień prawdziwości T wg [9], a `MultiSubjectGenerator` generuje kandydatów dla zadanej pary podmiotów.

Pakiet data – dostęp do bazy. `CarRecord` (rekord) przechowuje wartości atrybutów jednego pojazdu. `DbImporter` ładuje przefiltrowany plik CSV do bazy SQLite, a `CarDataLoader` czyta rekordy przez JDBC; `Columns` centralizuje nazwy kolumn. `DataCleaner` to jednorazowe narzędzie selekcji kolumn i odrzucenia rekordów z brakami (przygotowanie zbioru roboczego).

3.3 Wymagania uruchomieniowe

Aplikacja wymaga **JDK/JRE w wersji 25 (Java 25 LTS)** – zgodnie z wymogiem „najnowsza wersja LTS” – oraz narzędzia **Apache Maven** do zbudowania i pobrania zależności. Baza danych nie wymaga osobnego serwera: SQLite jest wbudowany, plików baz relacyjnych, a sterownik `sqlite-jdbc` zawiera natywne biblioteki dla głównych systemów (Windows, Linux, macOS). Pozostałe zależności (`jFuzzyLogic` przez `JitPack`, `SLF4J/Logback`) są pobierane automatycznie przy budowaniu. Uruchomienie części obliczeniowej następuje przez `mvn exec:java` (lub z zbudowanego pakietu); przy pierwszym starcie zbiór roboczy jest importowany z pliku CSV do bazy `cars.db`, a kolejne uruchomienia czytają już z bazy.

4 Jednopodmiotowe podsumowania lingwistyczne. Miary jakości, podsumowanie optymalne

Wyniki kolejnych eksperymentów wg punktów 2.-4. opisu projektu 2. Listy podsumowa jednopodmiotowych i tabele/rankingi podsumowa dla danych atrybutów obowiązkowe i dokładnie opisane w „captions” (tytułach), konieczny opis kolumn i wierszy tabel. Dla każdego podsumowania podane miary jakości oraz miara jakości podsumowania optymalnego. **Wzorów podsumowa ani miar nie należy przepisywać ani cytować, wystarczy podać literaturę, ale należy skomentować co oznaczają i jak informacje niosą wybrane miary w wybranych przypadkach.**

Sekcja uzupełniona jako efekt zadania Tydzień 11 wg Harmonogramu Zaj na WIKAMP KSR.

5 Wielopodmiotowe podsumowania lingwistyczne i ich miary jakości

Wyniki kolejnych eksperymentów wg punktów 2.-4. opisu projektu 2. Uzasadnienie i metoda podziału zbioru danych na roczne podmioty. Listy podsumowa wielopodmiotowych i tabele/rankingi podsumowa dla danych atrybutów obowiązkowe i dokładnie opisane w „captions” (tytułach), konieczny opis kolumn i

wierszy tabel. **Wzorów podsumowa ani miar nie należy przepisywać ani cytować, wystarczy podać literaturę, ale należy skomentować co oznaczają i jak informacje noszą wybrane miary w wybranych przypadkach.** Konieczne uwzględnienie wszystkich 4-ech form podsumowania wielopodmiotowych.

** Moliwe sformułowanie zagadnienia wielopodmiotowego podsumowania optymalnego **.

** Ewentualne wyniki realizacji punktu „na ocen 5.0” wg opisu Projektu 2. i ich porównanie do wyników z części obowiązkowej **.

Sekcja uzupełniona jako efekt zadania Tydzień 12 wg Harmonogramu Zaj na WIKAMP KSR.

6 Dyskusja, wnioski

We wnioskach z badania skomentować wyczerpie wpływ wybranych parametrów (zbiorów rozmytych, zmiennych lingwistycznych, miar podobieństwa, itp.) na jako procesu klasyfikacji. Innymi słowami wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury.

Komentować należy wyczerpie zbiór danych i znaczenie otrzymanych podsumowań. Metody nie komentujemy.

Dokładne interpretacje uzyskanych wyników w zależności od parametrów opisanych w punktach 3.-4 opisu Projektu 2. Omówić i wyjaśnić napotkane problemy (jeśli będą). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: podsumowania i miar jakości). Ocena które podsumowania i dlaczego noszą najistotniejsze informacje i które ich miary jakości mają albo duże znaczenie dla wiarygodności i jakości otrzymanych agregacji/podsumowań.

Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdy prezentuje poziom zrozumienia rozwiązywanego problemu.

** Moliwość kontynuacji prac w obszarze logiki rozmytej i wnioskowania rozmytego, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadania Tydzień 11 i Tydzień 12 wg Harmonogramu Zaj na WIKAMP KSR.

7 Braki w realizacji projektu 2.

Wymienić wg opisu Projektu 2. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

- [1] A. Niewiadomski, *Zbiory rozmyte typu 2. Zastosowania w reprezentowaniu informacji*, Seria „Problemy współczesnej informatyki” pod redakcją L. Rutkowskiego, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2019.
- [2] S. Zadrony, *Zapytania nieprecyzyjne i lingwistyczne podsumowania baz danych*, EXIT, Warszawa, 2006.
- [3] A. Niewiadomski, *Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions*, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2008.
- [4] L. A. Zadeh, „The concept of a linguistic variable and its application to approximate reasoning”, *Information Sciences*, vol. 8, nr 3, ss. 199–249, 1975.
- [5] L. A. Zadeh, „A computational approach to fuzzy quantifiers in natural languages”, *Computers & Mathematics with Applications*, vol. 9, nr 1, ss. 149–184, 1983.
- [6] R. R. Yager, „A new approach to the summarization of data”, *Information Sciences*, vol. 28, nr 1, ss. 69–86, 1982.
- [7] J. Kacprzyk, R. R. Yager, „Linguistic summaries of data using fuzzy logic”, *International Journal of General Systems*, vol. 30, nr 2, ss. 133–154, 2001.
- [8] J. Islam, *Car Specification Dataset 1945–2020*, Kaggle, 2020.
<https://www.kaggle.com/datasets/jahaidulislam/car-specification-dataset-1945-2020>
- [9] A. Niewiadomski, I. Superson, „On multi-subjectivity in linguistic summarization of relational databases”, *Journal of Theoretical and Applied Computer Science*, vol. 8, nr 1, ss. 15–34, 2014.
- [10] P. Cingolani, J. Alcalá-Fdez, „jFuzzyLogic: a Java library to design fuzzy logic controllers according to the standard for fuzzy control programming”, *International Journal of Computational Intelligence Systems*, vol. 6, sup. 1, ss. 61–75, 2013.

Literatura zawiera wyczerpujące recenzje i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.