

Komputerowe systemy rozpoznawania

2024/2025

Projekt 2. Podsumowania lingwistyczne relacyjnych baz danych

Mateusz Kosowski 251558
Nikodem Nowak 251598
dr inż. Marcin Kacprowicz

1 czerwca 2026

Opis projektu ma formę artykułu naukowego lub raportu z zadania badawczego (doświadczalnego/obliczeniowego (wg indywidualnych potrzeb związanych np. z pracą inżynierską/naukową/zawodową). Wzory są numerowane, tablice są numerowane i podpisane nad tablicą, rysunki są numerowane i podpisane pod rysunkiem. Podpis rysunku i tabeli musi być wyczerpujący (nie ogólnikowy), aby czytelnik nie musiał sięgać do tekstu, aby go zrozumieć.

Limit stron sprawozdania: 20. Nie zmieniać parametrów tekstu (czcionki, marginesów, interlinii, itp.). Istotne dla sprawozdania rysunki, tabele, informacje, kody itp. można umieścić w załącznikach, które nie wliczają się do limitu stron.

Kolejne sekcje sprawozdania są uzupełniane wg wymagań w opisie Projektu 2. i Harmonogramie Zajęć na WIKAMP KSR jako efekty zadań w poszczególnych tygodniach.

1 Cel

Celem projektu jest implementacja aplikacji desktopowej w technologii JDK (Java 25 LTS) generującej *lingwistyczne podsumowania* relacyjnej bazy danych w formie zdań języka quasi-naturalnego. Aplikacja udostępnia graficzny interfejs użytkownika, który dla użytkownika niezaawansowanego pozwala wygenerować podsumowania na podstawie predefiniowanych sumaryzatorów, kwalifikatorów i kwantyfikatorów (np. „samochody tanie i stare”), zdefiniować wagi w_i dla miar jakości, posortować podsumowania według wybranej miary i zapisać wybrane wyniki do pliku tekstowego, a dla użytkownika zaawansowanego dodatkowo zdefiniować nowe etykiety i funkcje przynależności.

Aplikacja generuje dwa rodzaje podsumowań:

- **jednopodmiotowe** – w pierwszej formie postaci „ Q obiektów ze zbioru ma własność S ” i drugiej formie postaci „ Q obiektów ze zbioru będących W ma własność S ”;
- **wielopodmiotowe** – we wszystkich czterech formach (I.–IV.), porównujących dwa rozłączne podmioty P_1, P_2 ze zbioru (np. dwie różne marki samochodów),

gdzie Q jest *kwantyfikatorem lingwistycznym* (np. „większość”, „około połowy”), a S i W są *sumaryzatorami* (kwalifikatorami) zbudowanymi z etykiet zmiennych lingwistycznych powiązanych z atrybutami bazy – prostymi lub złożonymi za pomocą spójników logicznych. Dla każdego wygenerowanego podsumowania aplikacja wyznacza miary jakości od T_1 do T_{11} oraz miarę podsumowania optymalnego, na podstawie których zwracane są uporządkowane rankingi podsumowań.

Aplikacja obsługuje trzy rodziny funkcji przynależności: trójkątną, trapezoidalną i gaussowską. Dla wszystkich zmiennych lingwistycznych i kwantyfikatorów w sprawozdaniu wybrano funkcje **trapezoidalne** – mają one prostą czteroparametrową definicję, pozwalają w naturalny sposób uczynić skrajne etykiety lewo- i prawo-otwartymi oraz łatwo zapewnić rozmyte pokrycie zupełne uniwersum (sąsiednie etykiety nakładają się tak, że suma ich stopni przynależności wynosi 1).

Eksperymenty są prowadzone na podzbiorze 23 441 rekordów ze zbioru *Car Specification Dataset 1945–2020* (Kaggle, [8]), gromadzącego dane techniczne wersji wyposażenia samochodów osobowych z lat 1945–2020. Z oryginalnej bazy wybrano 12 atrybutów numerycznych (rozmywanych do zmiennych lingwistycznych) oraz 3 atrybuty nominalne (klucz, marka, model). Po odfiltrowaniu rekordów z brakującymi wartościami otrzymano spójny zbiór wszystkich rekordów tego samego typu, do którego zastosowanie narzędzi logiki rozmytej daje konkretne, zrozumiałe wnioski o całej populacji aut.

Spodziewanym efektem jest zbiór rankingów podsumowań posortowanych według miar jakości oraz wskazanie, które z miar T_1 – T_{11} niosą największą informację o badanej populacji aut, a także które kombinacje sumaryzatorów i kwantyfikatorów dają wartościowe (a które trywialne lub mylące) opisy zawartości bazy.

2 Baza danych, zmienne lingwistyczne, kwantyfikatory lingwistyczne

2.1 Charakterystyka podsumowywanej bazy danych

Wykorzystany zbiór *Car Specification Dataset 1945–2020* [8] zawiera 70 823 rekordów wersji wyposażenia samochodów osobowych (*trim level*) z 255 marek, wyprodukowanych w latach 1945–2020, opisanych 78 atrybutami; zbiór jest dostępny publicznie w serwisie Kaggle. Każdy rekord opisuje pojedynczą wersję wyposażenia jednego modelu, charakteryzując ją zestawem cech technicznych

(wymiały, masa, parametry silnika, osiągi, zużycie paliwa, geometria podwozia). Tego rodzaju dane są w motoryzacji rutynowo opisywane językiem naturalnym – klient czy dziennikarz motoryzacyjny mówi raczej o „mocnym silniku”, „dużym SUV-ie” albo „paliwożernym aucie” niż o konkretnych wartościach liczbowych 312 KM, 5 300 mm czy 11,3 l/100 km. Z tego powodu zbiór dobrze nadaje się do podsumowywania metodami logiki rozmytej – pozwala automatycznie generować zdania, które są intuicyjne dla człowieka, a trudne do uzyskania zwykłymi zapytaniami SQL.

Wybór atrybutów i filtracja. Z 78 oryginalnych kolumn wybrano **12 atrybutów numerycznych** podlegających rozmywaniu (są to atrybuty mierzalne, każdy z wieloma setkami unikalnych wartości) oraz **3 atrybuty nominalne** pełniące funkcję klucza i etykiet podmiotów w podsumowaniach wielopodmiotowych. Z bazy odrzucono rekordy, w których przynajmniej jedna z 15 wybranych kolumn miała wartość pustą. Wynikowy zbiór roboczy liczy **23 441 rekordów tego samego typu** (z 88 marek), co spełnia wymóg minimum 10 000 rekordów w projekcie. Pełną listę atrybutów wraz z jednostkami i empirycznymi zakresami przedstawia tabela 1.

Tabela 1: Lista 15 atrybutów wybranych ze zbioru *Car Specification Dataset 1945–2020* [8]: 12 numerycznych podlegających rozmyciu (zmienne lingwistyczne) oraz 3 nominalne wykorzystywane jako klucz/podmiot. Kolumna „zakres” podaje zaobserwowane minimum i maksimum w roboczym podzbiorze 23 441 rekordów.

Atrybut (kolumna CSV)	Opis	Jednostka	Zakres
<i>Atrybuty nominalne (klucz/podmiot):</i>			
id_trim	Identyfikator wersji wyposażenia	—	—
Make	Marka pojazdu	—	88 marek
Model	Model pojazdu	—	—
<i>Atrybuty numeryczne (zmienne lingwistyczne):</i>			
length_mm	Długość całkowita pojazdu	mm	1 826 – 6 165
wheelbase_mm	Rozstaw osi	mm	1 397 – 3 872
curb_weight_kg	Masa własna pojazdu	kg	625 – 3 000
minimum_trunk_capacity_l	Pojemność bagażnika	l	11 – 4 400
maximum_torque_n_m	Maksymalny moment obrotowy	Nm	44 – 1 017
capacity_cm3	Pojemność skokowa silnika	cm ³	599 – 7 443
engine_hp	Moc silnika	KM	29 – 710
turning_circle_m	Średnica zawracania	m	5,9 – 19,5
mixed_fuel_consumption_per_100_km_l	Spalanie mieszane	l/100 km	1,4 – 36,5
fuel_tank_capacity_l	Pojemność zbiornika paliwa	l	10 – 159
acceleration_0_100_km/h_s	Czas przyspieszenia 0–100 km/h	s	2,7 – 33,2
max_speed_km_per_h	Prędkość maksymalna	km/h	100 – 348

Aby spełnić wymóg projektu dotyczący dostępu przez DBMS, przefiltrowane dane są ładowane do pliku bazy **SQLite** (**cars.db**) jako pojedyncza tabela **cars** i odczytywane przez aplikację Javową przez sterownik **JDBC**. **SQLite** to w pełni relacyjny, plikowy system zarządzania bazą danych – nie wymaga osobnego serwera, ale obsługuje **SQL** i transakcje dokładnie tak jak duże silniki (**PostgreSQL**, **MySQL**). Fragment zawartości tabeli po wczytaniu przedstawia tabela 2.

Tabela 2: Fragment podzbioru roboczego (5 z 23 441 rekordów). Kolumny zostały skrócone do najważniejszych atrybutów dla zachowania czytelności; pełny zestaw 15 atrybutów – tabela 1. Wartości przepisane bez modyfikacji ze zbioru źródłowego.

Make	Model	dł. [mm]	masa [kg]	poj. [cm ³]	moc [KM]	0–100 [s]	$V_{\max}$ [km/h]	sp. [l]
BMW	320i	4 624	1 495	1 998	184	7,3	235	5,9
Volkswagen	Golf VII	4 255	1 205	1 395	122	9,1	203	4,9
Ford	Fiesta VI	3 950	1 041	1 242	82	13,3	168	5,1
Mercedes-Benz	S 500	5 246	2 065	4 663	455	4,8	250	9,1
Toyota	Aygo II	3 455	840	998	72	14,2	160	4,1

2.2 Zmienne lingwistyczne (atrybuty/własności obiektów)

Każdy z 12 atrybutów numerycznych potraktowano jako **zmienną lingwistyczną**, czyli atrybut, którego wartości można opisywać słowami z języka naturalnego zamiast surowych liczb – np. zamiast „300 KM” mówimy „silnik dynamiczny”. Dla każdej zmiennej trzeba ustalić trzy rzeczy:

- **przestrzeń rozważań** X – zakres wartości liczbowych atrybutu wyrażony w jego naturalnej jednostce (np. dla mocy silnika $X = [0, 800]$ KM);
- **zestaw etykiet** – słowa, którymi opisujemy wartości z X (np. „anemiczny / słaby / przyzwoity / dynamiczny / wyczynowy”);
- **funkcję przynależności** $\mu(x) \in [0, 1]$ dla każdej etykiety – mówi ona, w jakim stopniu konkretna wartość liczbową x pasuje do danej etykiety (1 = w pełni, 0 = w ogóle).

Konwencja etykiet. Dla każdej z 12 zmiennych przyjęto **pięcioelementowy** zbiór etykiet $\mathcal{T}$ uporządkowany według rosnącej wartości atrybutu, lecz *dobrany indywidualnie* do zmiennej z naturalnego, polskiego słownictwa motoryzacyjnego – pozwala to uniknąć monotonnego „bardzo mała / mała / średnia / duża / bardzo duża” i nadać każdej zmiennej własny, czytelny dla człowieka charakter (np. masa: „piórkowy – masywny”; moc: „anemiczny – wyczynowy”; spalanie: „oszczędny – rozrzutny”). Pełną listę etykiet dla każdej zmiennej zawierają tabele 3–14 w kolejnych podpunktach. Pięcioelementowy zestaw daje wystarczająco bogatą semantykę dla podsumowań kolejnych tygodni (zarówno jedno-, jak i wielopodmiotowych) przy zachowaniu czytelności wykresów; ujednolicenie liczby etykiet we wszystkich zmiennych ułatwia konstruowanie sumarytorów złożonych i porównywanie miar jakości między zmiennymi.

Funkcje przynależności. We wszystkich 12 zmiennych lingwistycznych i we wszystkich kwantyfikatorach (§2.3) używamy **funkcji trapezoidalnej** – ma

cztery parametry $a \leq b \leq c \leq d$ i postać:

$$\mu_{(a,b,c,d)}(x) = \begin{cases} 0, & x \leq a \text{ lub } x \geq d, \\ \frac{x-a}{b-a}, & a < x < b, \\ 1, & b \leq x \leq c, \\ \frac{d-x}{d-c}, & c < x < d. \end{cases} \quad (1)$$

Pierwsza i ostatnia etykieta każdej zmiennej (np. „piórkowy” i „masywny” dla masy) są odpowiednio *lewo-* i *prawo-otwarte*: dla pierwszej przyjęto $a = b = x_{\min}$, a dla ostatniej $c = d = x_{\max}$ – dzięki temu zakres jest w całości pokryty (skrajne wartości należą do odpowiednio pierwszej lub ostatniej etykiety w stopniu 1). Sąsiednie trapezy są tak dobrane, że się ze sobą nakładają – dla każdej wartości x suma stopni przynależności do wszystkich pięciu etykiet wynosi w przybliżeniu 1, a w punkcie przejścia między sąsiednimi etykietami obie mają stopień 0,5 (przykład: wykres mocy silnika w osobnym załączniku).

Dobór parametrów. Wartości parametrów (a, b, c, d) dla każdej z 5 etykiet wszystkich 12 zmiennych zebranych w tabelach 3–14 dobraliśmy w ten sam sposób: tak, żeby pasowały zarówno do faktycznego rozkładu danych w zbiorze (kwantyle 5 %, 25 %, 50 %, 75 %, 95 %), jak i do ogólnych zasad obowiązujących w motoryzacji. W podpisach tabel informacja ta nie jest powtarzana.

W kolejnych podpunktach dla każdej zmiennej podano: przestrzeń rozważań X oraz tabelę parametrów (a, b, c, d) wszystkich pięciu etykiet. Aby zmieścić się w limicie stron, odpowiadające im wykresy funkcji przynależności (linią ciągłą, z zaznaczonym obszarem wsparcia) zebrano w **osobnym załączniku** (plik `Zalaczniki.pdf`); tam też znajdują się wykresy obu rodzin kwantyfikatorów z §2.3.

2.2.1 Długość pojazdu (`length_mm`), $X = [1500, 6500]$ mm

Tabela 3: Parametry trapezowych funkcji przynależności dla zmiennej lingwistycznej „długość pojazdu”.

Etykieta	a	b	c	d
krótki	1 500	1 500	3 500	3 900
kompaktowy	3 500	3 900	4 200	4 500
standardowy	4 200	4 500	4 700	4 900
długi	4 700	4 900	5 100	5 300
wielkogabarytowy	5 100	5 300	6 500	6 500

2.2.2 Rozstaw osi (wheelbase_mm), $X = [1300, 4000]$ mm

Tabela 4: Parametry trapezowych funkcji przynależności dla zmiennej „rozstaw osi”.

Etykieta	a	b	c	d
zwarty	1 300	1 300	2 300	2 450
krótki	2 300	2 450	2 550	2 650
standardowy	2 550	2 650	2 750	2 850
wydłużony	2 750	2 850	2 950	3 050
limuzynowy	2 950	3 050	4 000	4 000

2.2.3 Masa własna (curb_weight_kg), $X = [500, 3500]$ kg

Tabela 5: Parametry trapezowych funkcji przynależności dla zmiennej „masa własna”.

Etykieta	a	b	c	d
piórkowy	500	500	900	1 100
lekki	900	1 100	1 250	1 400
średnio ciężki	1 250	1 400	1 500	1 650
ciężki	1 500	1 650	1 850	2 050
masywny	1 850	2 050	3 500	3 500

2.2.4 Pojemność bagażnika (minimum_trunk_capacity_l), $X = [0, 1500]$ l

Tabela 6: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność bagażnika”. Górna granica uniwersum ograniczona do 1500 l (rzadkie vany cargo z >3000 l są wciąż poprawnie sklasyfikowane jako „ładunkowy”).

Etykieta	a	b	c	d
symboliczny	0	0	200	300
ciasny	200	300	350	400
standardowy	350	400	450	500
pojemny	450	500	600	700
ładunkowy	600	700	1 500	1 500

2.2.5 Moment obrotowy (maximum_torque_n_m), $X = [0, 1100]$ Nm

Tabela 7: Parametry trapezowych funkcji przynależności dla zmiennej „maksymalny moment obrotowy silnika”.

Etykieta	a	b	c	d
wiotki	0	0	100	150
miękki	100	150	180	230
zrównoważony	180	230	280	350
mocarny	280	350	450	550
potężny	450	550	1 100	1 100

2.2.6 Pojemność skokowa silnika (capacity_cm3), $X = [400, 8000]$ cm³

Tabela 8: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność skokowa”.

Etykieta	a	b	c	d
miniaturowy	400	400	1 200	1 400
małolitrażowy	1 200	1 400	1 600	1 800
średnolitrażowy	1 600	1 800	2 000	2 500
wielkolitrażowy	2 000	2 500	3 500	4 500
gigantyczny	3 500	4 500	8 000	8 000

2.2.7 Moc silnika (engine_hp), $X = [0, 800]$ KM

Tabela 9: Parametry trapezowych funkcji przynależności dla zmiennej „moc silnika”.

Etykieta	a	b	c	d
anemiczny	0	0	70	100
słaby	70	100	120	150
przyzwoity	120	150	180	220
dynamiczny	180	220	300	400
wyczynowy	300	400	800	800

2.2.8 Średnica zawracania (turning_circle_m), $X = [5, 20]$ m

Tabela 10: Parametry trapezowych funkcji przynależności dla zmiennej „średnica zawracania”.

Etykieta	a	b	c	d
zwinny	5,0	5,0	9,5	10,0
zwrotny	9,5	10,0	10,5	11,0
przeciętny	10,5	11,0	11,3	11,7
nieporęczny	11,3	11,7	12,5	13,5
ociężały	12,5	13,5	20,0	20,0

2.2.9 Spalanie mieszane (mixed_fuel_consumption_per_100_km_l), $X = [0, 25]$ l/100 km

Tabela 11: Parametry trapezowych funkcji przynależności dla zmiennej „spalanie mieszane”.

Etykieta	a	b	c	d
oszczędny	0	0	4	5
ekonomiczny	4	5	6	7
umiarkowany	6	7	8	10
paliwożerny	8	10	12	15
rozrzutny	12	15	25	25

2.2.10 Pojemność zbiornika paliwa (fuel_tank_capacity_l), $X = [10, 160]$ l

Tabela 12: Parametry trapezowych funkcji przynależności dla zmiennej „pojemność zbiornika paliwa”.

Etykieta	a	b	c	d
mały	10	10	40	45
niewielki	40	45	50	55
standardowy	50	55	65	70
pojemny	65	70	80	90
ogromny	80	90	160	160

2.2.11 Czas przyspieszenia 0–100 km/h (`acceleration_0_100_km/h_s`),
 $X = [2, 25]$ s

Tabela 13: Parametry trapezowych funkcji przynależności dla zmiennej „czas przyspieszenia 0–100 km/h”. Etykiety opisują samochód poprzez jego dynamikę: niska wartość czasu odpowiada autu „raketowemu”, wysoka – „ślamazarnemu”.

Etykieta	a	b	c	d
raketowy	2	2	5	6
szybki	5	6	8	9
przeciętny	8	9	11	13
ospały	11	13	15	17
ślamazarny	15	17	25	25

2.2.12 Prędkość maksymalna (`max_speed_km_per_h`), $X = [80, 360]$ km/h

Tabela 14: Parametry trapezowych funkcji przynależności dla zmiennej „prędkość maksymalna”.

Etykieta	a	b	c	d
powolny	80	80	150	165
miejski	150	165	180	195
autostradowy	180	195	210	230
wyścigowy	210	230	250	280
błyskawiczny	250	280	360	360

2.3 Kwantyfikatory lingwistyczne (liczności obiektów)

Kwantyfikatory lingwistyczne to słowa, które w zdaniu „ Q obiektów ze zbioru ma własność S ” stoją w miejscu Q – np. „większość”, „około połowy”, „prawie wszystkie”. Każdy kwantyfikator opisujemy zbiorem rozmytym z trapezową funkcją przynależności, dokładnie tak samo jak zmienne lingwistyczne (§2.2), tylko że na innej dziedzinie. Rozróżniamy dwa rodzaje kwantyfikatorów:

- **względne (proporcjonalne)** – argumentem jest *udział* obiektów spełniających warunek, $r \in [0, 1]$ (np. „około połowy” = $r \approx 0,5$);
- **bezwzględne (absolutne)** – argumentem jest *liczba* obiektów spełniających warunek, $r \in \mathbb{N}$ (np. „kilka tysięcy” = $r \approx$ kilka tysięcy rekordów).

2.3.1 Kwantyfikatory względne

Przestrzeń rozważań $X_Q = [0, 1]$. Pięć etykiet pokrywa cały odcinek $[0, 1]$ z przejściami w okolicach typowych progów intuicji ($\sim 0,1$ – „prawie żaden”, $\sim 0,5$ – „około połowy”, $\sim 0,9$ – „prawie wszystkie”).

Tabela 15: Parametry trapezowych funkcji przynależności pięciu kwantyfikatorów względnych. Argumentem jest proporcja $r \in [0, 1]$ obiektów spełniających warunek.

Etykieta	a	b	c	d
prawie żaden	0,00	0,00	0,05	0,20
mniejszość	0,05	0,20	0,30	0,40
około połowy	0,30	0,40	0,60	0,70
większość	0,60	0,70	0,85	0,95
prawie wszystkie	0,85	0,95	1,00	1,00

2.3.2 Kwantyfikatory bezwzględne

Przestrzeń rozważań $X_Q^{\text{abs}} = [0, 25\,000]$ – górna granica wzięta nieco powyżej liczności podzbioru roboczego (23 441 rekordów), aby etykieta „dużo” była aktywna dla niemal całej populacji bazy, gdy podsumowanie obejmuje praktycznie wszystkie rekordy. Przyjęto cztery etykiety zamiast pięciu, ponieważ na osi liczności (w przeciwieństwie do osi proporcji) różnice rzędu wielkości są bardziej istotne niż różnice o stałym kroku, a granice odpowiadają intuicji „bardzo mało / kilka tysięcy / kilkanaście tysięcy / dużo”.

Tabela 16: Parametry trapezowych funkcji przynależności czterech kwantyfikatorów bezwzględnych. Argumentem jest liczba (rekordów) obiektów spełniających warunek.

Etykieta	a	b	c	d
bardzo mało	0	0	1 000	3 000
kilka tysięcy	1 000	3 000	6 000	8 000
kilkanaście tysięcy	6 000	8 000	14 000	16 000
dużo	14 000	16 000	25 000	25 000

3 Narzędzia obliczeniowe: wybór/implementacja. Diagram UML klas do obliczeń rozmytych i generowania podsumowań

3.1 Źródło pakietu obliczeniowego

Pakiet obliczeń rozmytych ma charakter **hybrydowy**. Trzon – reprezentacja zbiorów rozmytych i ich własności, zmiennych lingwistycznych, kwantyfikatorów, sumaryzatorów/kwalifikatorów oraz podsumowań i ich miar jakości – jest *własną* implementacją, opartą o definicje z literatury przedmiotu ([4], [5], [6], [7], [3]; podsumowania wielopodmiotowe wg [9]). Jako składnik *zewnętrzny* użyto wyłącznie biblioteki `jFuzzyLogic` [10] – i to tylko do liczenia wartości trzech

funkcji przynależności (trójkątnej, trapezoidalnej, gaussowskiej). Dostęp do danych realizuje sterownik `sqlite-jdbc` (relacyjna baza SQLite przez JDBC), a logowanie – SLF4J/Logback. Całość budowana jest narzędziem Maven; zależności pobierane są automatycznie (`jFuzzyLogic` z repozytorium JitPack).

3.2 Charakterystyka najważniejszych klas


Poniżej zwięźły opis klas, ich pól oraz kluczowych metod. Dla czytelności diagram klas rozbito na rysunki odpowiadające najważniejszym grupom pakietów. W raporcie pokazano diagramy dotyczące generowania i oceny podsumowań (rys. 1–2), a pomocnicze diagramy pakietów rozmytych, dostępu do danych i GUI przeniesiono do załącznika. Klasy używane z innych pakietów pokazano jako odnośniki (puste boksy) w ramce „z innych pakietów”.

Pakiet `fuzzy.set` – zbiory i przestrzeń rozważań. `Universe` reprezentuje przestrzeń rozważań w dwóch wariantach: gęstym (`continuous`, równomierne próbkowanie) i dyskretnym (`discrete`, co 1); metoda `samplePoints()` dostarcza punkty siatki do numerycznego liczenia własności. `FuzzySet` łączy nazwę, przestrzeń i funkcję przynależności; udostępnia własności wymagane w zadaniu – `height()`, `support()`, `alphaCut()`, `isNormal()`, `isEmpty()`, `isConvex()` – operacje teoriomnogościowe (`complement`, `union`, `intersect`) oraz względne liczności nośnika i σ -count używane przez miary jakości. `ClassicSet` to odpowiednik zbioru klasycznego (twardy predykat 0/1) z tymi samymi operacjami. `Interval` (rekord) opisuje nośnik/ α -przekrój.

Pakiet `fuzzy.mf` – funkcje przynależności. Interfejs funkcyjny `MembershipFunction` ma jedną metodę `degree(x)`. Klasy `TriangularMf`, `TrapezoidalMf`, `GaussianMf` delegują obliczenie do `jFuzzyLogic` (z przycięciem wyniku do $[0, 1]$). `Operations` dostarcza dopełnienie, sumę (t-konorma maksimum) i iloczyn (t-norma minimum) jako dekoratory funkcji przynależności.

Pakiet `fuzzy.linguistic` – warstwa lingwistyczna. `LinguisticVariable` wiąże atrybut bazy z przestrzenią rozważań i zestawem etykiet; `degreeOf(label, x)` i `isValid(x)` obsługują przeliczanie i odrzucanie braków danych. `Label` (rekord) to nazwana etykieta nad zbiorem rozmytym. `Quantifier` reprezentuje kwantyfikator względny lub bezwzględny; `degree(quantity)` zwraca stopień dopasowania proporcji lub liczności.

Pakiet `summary` – podsumowania jednopodmiotowe. Interfejs `LabelExpression` (z implementacjami `Property` – pojedyncza etykieta, oraz `Connective` – złożenie spójnikiem AND/OR) reprezentuje sumaryzator lub kwalifikator i liczy stopień przynależności rekordu (`degree(rec)`). `SingleSubjectSummary` składa kwantyfikator, opcjonalny kwalifikator i sumaryzator w zdanie (`sentence()`) w pierwszej lub drugiej formie. `SummaryGenerator` produkuje zbiory kandydujących podsumowań na podstawie konfiguracji.



Rysunek 1: Diagram klas pakietów `config`, `summary` i `summary.quality`: konfiguracja zmiennych i kwantyfikatorów (`FuzzyConfig`); wyrażenia summaryzatora/kwalifikatora – interfejs `LabelExpression` z implementacjami `Property` (pojedyncza etykieta) i `Connective` (złożenie spójnikami AND/OR); zdanie jednopodmiotowe i jego generator (`SingleSubjectSummary`, `SummaryGenerator`); miary jakości T_1 – T_{11} wraz z podsumowaniem optymalnym (`QualityMeasures`, rekord `Quality`, `QualityWeights`). Klasy `LinguisticVariable`, `Label`, `Quantifier` i `CarRecord` pochodzą z innych pakietów (ramka u dołu).


Pakiet `summary.quality` – miary jakości. `QualityMeasures.evaluate(...)` wyznacza w jednym przebiegu po rekordach komplet miar T_1 – T_{11} oraz wartość podsumowania optymalnego, zwracając rekord `Quality`. `QualityWeights` przechowuje znormalizowane wagi miar (sterowane z GUI) i liczy ważoną sumę.

Pakiet `summary.multi` – podsumowania wielopodmiotowe. `Subject` to nazwany predykat wyróżniający rozłączny podmiot (np. `ofMake` – jedna marka). `MultiSubjectSummary` reprezentuje cztery formy (I–IV) porównujące podmioty P_1 , P_2 , z fabrykami `formI` / `formII` / `formIII` / `formIV` i metodą `sentence()`. `MultiSubjectMeasures.degreeOfTruth(...)` liczy stopień prawdziwości T wg [9], a `MultiSubjectGenerator` generuje kandydatów dla zadanej pary podmiotów.

Pakiet `data` – dostęp do bazy. `CarRecord` (rekord) przechowuje wartości atrybutów jednego pojazdu. `DbImporter` ładuje przefiltrowany plik CSV do bazy SQLite, a `CarDataLoader` czyta rekordy przez JDBC; `Columns` centralizuje nazwy kolumn. `DataCleaner` to jednorazowe narzędzie selekcji kolumn i odrzucenia rekordów z brakami (przygotowanie zbioru roboczego).

3.3 Wymagania uruchomieniowe

Aplikacja wymaga **JDK/JRE w wersji 25 (Java 25 LTS)** – zgodnie z wymogiem „najnowsza wersja LTS” – oraz narzędzia **Apache Maven** do zbudowania.



Rysunek 2: Diagram klas pakietu `summary.multi` – podsumowania wielopodmiotowe w formach I–IV: `MultiSubjectSummary` (z wyliczeniem `Form` i fabrykami `formI`–`formIV`), wyróżnianie rozłącznych podmiotów `Subject` (np. `ofMake`), stopień prawdziwości T (`MultiSubjectMeasures`) oraz generator kandydatów (`MultiSubjectGenerator`). Zależności do `Quantifier`, `LabelExpression`, `FuzzyConfig` i `CarRecord` prowadzą do klas z innych pakietów (ramka u dołu).

wania i pobrania zależności. Baza danych nie wymaga osobnego serwera: SQLite jest wbudowaną, plikową bazą relacyjną, a sterownik `sqlite-jdbc` zawiera natywne biblioteki dla głównych systemów (Windows, Linux, macOS). Pozostałe zależności (`jFuzzyLogic` przez `JitPack`, `SLF4J/Logback`) są pobierane automatycznie przy budowaniu. Uruchomienie części obliczeniowej następuje przez `mvn exec:java` (lub z zbudowanego pakietu); przy pierwszym starcie zbiór roboczy jest importowany z pliku CSV do bazy `cars.db`, a kolejne uruchomienia czytają już z bazy.

4 Jednopodmiotowe podsumowania lingwistyczne. Miary jakości, podsumowanie optymalne

4.1 Metodyka eksperymentu

Eksperymenty przeprowadzono na całym roboczym podzbiorze $n = 23\,441$ rekordów (§2.1); rekordy z brakującą wartością któregośkolwiek atrybutu użytego w danym podsumowaniu są pomijane przy liczeniu miar. Generator wylicza pełne przestrzenie kandydatów:

- **forma I, sumaryzator prosty, kwantyfikatory względne** – 12 zmiennych $\times 5$ etykiet $\times 5$ kwantyfikatorów = 300 podsumowań;

- **forma I, kwantyfikatory bezwzględne** – $12 \times 5 \times 4 = 240$ podsumowań;
- **forma II** z ustalonym kwalifikatorem „masa = ciężki” – $11 \times 5 \times 5 = 275$ podsumowań;
- **sumaryzatory złożone** (koniunkcja/alternatywa dwóch lub trzech etykiet różnych zmiennych) – wybrane przykłady demonstracyjne.

Każdemu podsumowaniu przypisano komplet 11 miar jakości T_1 – T_{11} o wartościach w $[0, 1]$ (wyższa = lepsza), wyznaczonych w jednym przebiegu po rekordach wg definicji z literatury ([6], [7], [2], [3]); zgodnie z wymaganiami wzorów nie przytaczamy, a znaczenie poszczególnych miar komentujemy przy konkretnych wynikach. Skrótowy sens wszystkich miar zestawia tabela w **osobnym załączniku** (plik `Zalaczniki.pdf`). *Podsumowanie optymalne* to ważona suma $T = \sum_i w_i T_i$; we wszystkich rankingach przyjęto wagi równe $w_i = \frac{1}{11}$ (sterowalne z GUI), zatem T jest tu średnią arytmetyczną jedenastu miar. Rankingi sortujemy malejąco wg T ; w tabelach 17–20 podajemy pierwszą dziesiątkę (lub komplet przykładów) wraz z wszystkimi miarami i wartością T (kolumna „opt”).

4.2 Forma I: sumaryzator prosty, kwantyfikatory względne

Tabela 17 przedstawia czołówkę rankingu 300 podsumowań pierwszej formy z kwantifikatorami względnymi. Pierwsze miejsca zajmują zdania w pełni prawdziwe ($T_1 = 1,000$): „Okolo połowy aut ma długość standardową”, „Okolo połowy aut ma standardowy rozstaw osi”. Wysoki T_1 oznacza, że *względna σ -count* sumaryzatora (proporcja aut o danej własności) trafia w nośnik kwantifikatora w stopniu 1 – np. ok. połowy rekordów ma „standardową” długość, co idealnie pasuje do kwantifikatora „okolo połowy”.

Tabela 17: Forma I, sumaryzator prosty, kwantyfikatory względne – pierwsza dziesiątka spośród 300 podsumowań w rankingu wg podsumowania optymalnego T (wagi równe). Kolumny: nr pozycji; kwantifikator Q ; sumaryzator S (zmienna lingwistyczna = etykieta); miary T_1 – T_8 ; wartość optymalna „opt” = $\frac{1}{11} \sum_i T_i$. Miary T_9 – T_{11} pominięto w tabeli, gdyż w formie I są równe 0 (i jako takie wchodzą do średniej T). Każdy wiersz to jedno podsumowanie wraz z kompletem swoich miar.

#	Q	S (zmienna = etykieta)	T_1	T_2	T_3	T_4	T_5	T_6	T_7	T_8	opt
1	okolo połowy	długość = standardowy	1,000	0,860	0,694	0,000	1,000	0,600	0,700	0,910	0,524
2	okolo połowy	rozstaw osi = standardowy	1,000	0,889	0,621	0,000	1,000	0,600	0,700	0,926	0,522
3	mniejsość	śr. zawracania = zwrotny	1,000	0,900	0,435	0,000	1,000	0,650	0,775	0,933	0,518
4	mniejsość	poj. bagażnika = standardowy	1,000	0,901	0,429	0,000	1,000	0,650	0,775	0,933	0,517
5	mniejsość	moment obrotowy = miękki	1,000	0,882	0,426	0,000	1,000	0,650	0,775	0,927	0,515
6	mniejsość	rozstaw osi = krótki	1,000	0,871	0,426	0,000	1,000	0,650	0,775	0,917	0,513
7	okolo połowy	śr. zawracania = przeciętny	0,904	0,920	0,564	0,000	1,000	0,600	0,700	0,950	0,513
8	mniejsość	moment obrotowy = zrównoważony	0,997	0,846	0,454	0,000	1,000	0,650	0,775	0,900	0,511
9	mniejsość	poj. skokowa = małowitrazowy	1,000	0,921	0,314	0,000	1,000	0,650	0,775	0,947	0,510
10	mniejsość	spalanie = ekonomiczny	1,000	0,880	0,372	0,000	1,000	0,650	0,775	0,920	0,509

Co różnicuje ranking. Przy równym T_1 o kolejności decyduje **stopień pokrycia** T_3 : „długość = standardowy” realnie obejmuje 69,4 % rekordów ($T_3 =$

0,694) i stąd 1. miejsce, podczas gdy rzadsza „poj. skokowa = małowitrazowy” ($T_3 = 0,314$) spada na 9. pozycję mimo $T_1 = 1$. To pokazuje, że T_1 i T_3 są jedynymi miarami silnie zależnymi od zawartości bazy i to one niosą właściwą informację o danych. Pozostałe miary mają charakter *strukturalny*: $T_2, T_8 \approx 0,9$ (etykiety mają wąskie nośniki względem uniwersum, więc sumaryzator jest „ostry”), $T_5 = 1$ (sumaryzator jednoelementowy jest najkrótszy i najczytelniejszy), a T_6, T_7 zależą od wyboru kwantyfikatora (węższa „mniejszość”: $T_6 = 0,65$, jest bardziej specyficzna niż szersze „około połowy”: $T_6 = 0,60$). **Miara T_4 jest tożsamościowo zerowa** – dla sumaryzatora jednoelementowego degeneruje się do $|r_1 - T_3| = 0$ i nie niesie żadnej informacji; staje się użyteczna dopiero dla sumaryzatorów złożonych (§4.4).

4.3 Forma I: kwantyfikatory bezwzględne

Tabela 18 zawiera analogiczny ranking dla kwantyfikatorów bezwzględnych, w których argumentem jest *liczba* (a nie proporcja) rekordów spełniających sumaryzator. Czołówka jest niemal bliźniacza z formą względną – te same atrybuty (długość, rozstaw osi, średnica zawracania) zajmują pierwsze miejsca.

Tabela 18: Forma I, sumaryzator prosty, kwantyfikatory bezwzględne – pierwsza dziesiątka spośród 240 podsumowań (ranking wg T , wagi równe). Argumentem kwantyfikatora jest liczba rekordów spełniających sumaryzator. Kolumny jak w tab. 17; $T_9 - T_{11} = 0$ (forma I).

#	Q	S (zmienna = etykieta)	T_1	T_2	T_3	T_4	T_5	T_6	T_7	T_8	opt
1	kilkanaście tys.	długość = standardowy	1,000	0,860	0,694	0,000	1,000	0,600	0,680	0,910	0,522
2	kilkanaście tys.	rozstaw osi = standardowy	1,000	0,889	0,621	0,000	1,000	0,600	0,680	0,926	0,520
3	kilkanaście tys.	śr. zawracania = przeciętny	1,000	0,920	0,564	0,000	1,000	0,600	0,680	0,950	0,520
4	kilka tys.	poj. skokowa = małowitrazowy	1,000	0,921	0,314	0,000	1,000	0,720	0,800	0,947	0,518
5	kilka tys.	rozstaw osi = wydłużony	1,000	0,889	0,307	0,000	1,000	0,720	0,800	0,926	0,513
6	kilka tys.	poj. bagażnika = ciasny	1,000	0,867	0,336	0,000	1,000	0,720	0,800	0,917	0,513
7	kilka tys.	spalanie = ekonomiczny	0,927	0,880	0,372	0,000	1,000	0,720	0,800	0,920	0,511
8	kilka tys.	długość = długi	1,000	0,880	0,293	0,000	1,000	0,720	0,800	0,920	0,510
9	kilka tys.	poj. zbiornika = niewielki	1,000	0,900	0,240	0,000	1,000	0,720	0,800	0,933	0,509
10	kilka tys.	śr. zawracania = nieporęczny	1,000	0,853	0,309	0,000	1,000	0,720	0,800	0,900	0,507

Powtarzalność czołówki potwierdza, że o pozycji podsumowania decyduje pokrycie T_3 i kardynalność sumaryzatora T_8 , a nie rodzaj kwantyfikatora – ten jedynie dobiera etykietę liczności („kilkanaście tysięcy”, „kilka tysięcy”) pasującą do faktycznej liczby rekordów. Jedyna widoczna różnica to wartości T_6, T_7 , które tu opisują nośniki kwantyfikatorów na osi liczności: węższe „kilka tys.” ($T_7 = 0,800$) jest bardziej specyficzne niż szersze „kilkanaście tys.” ($T_7 = 0,680$).

4.4 Sumaryzatory złożone (koniunkcja i alternatywa)

Tabela 19 pokazuje trzy podsumowania ze złożonym sumaryzatorem, ujawniające zachowanie miar nieaktywnych w przypadku prostym. Wszystkie mają $T_1 = 0$: „Większość aut jest dynamiczna i paliwożerna” jest *fałszem*, bo koniunkcja (t-norma minimum) jest spełniana w znikomym stopniu – jedynie 13,9%

rekordów ($T_3 = 0,139$) wpada w oba warunki naraz, co nie sięga nośnika kwantyfikatora „większość” ($\geq 0,6$).

Tabela 19: Sumaryzatory złożone z kwantyfikatorem „większość” – dwie koniunkcje ($\wedge$, t-norma minimum) i jedna alternatywa ($\vee$, t-konorma maksimum). Kolumny jak w tab. 17. Mimo niezerowej wartości optymalnej wszystkie trzy podsumowania mają $T_1 = 0$ (są fałszywe); zob. komentarz w tekście.

#	Q	S (sumaryzator złożony)	T_1	T_2	T_3	T_4	T_5	T_6	T_7	T_8	opt
1	większość	$\text{moc} = \text{dynamiczny} \wedge \text{spalanie} = \text{paliwożerny}$	0,000	0,723	0,139	0,037	0,500	0,650	0,750	0,816	0,329
2	większość	$V_{\max} = \text{wyścigowy} \vee \text{moc} = \text{dynamiczny}$	0,000	0,738	0,387	0,301	0,500	0,650	0,750	0,827	0,378
3	większość	$\text{moc} = \text{dynamiczny} \wedge \text{spalanie} = \text{paliwożerny} \wedge V_{\max} = \text{wyścigowy}$	0,000	0,732	0,108	0,076	0,250	0,650	0,750	0,824	0,308

Przykład ten ilustruje trzy rzeczy. Po pierwsze, **wartości optymalnej nie wolno czytać jako prawdziwości**: opt = 0,33 przy $T_1 = 0$ bierze się z niezerowych miar strukturalnych (T_2, T_6, T_7, T_8), niezależnych od danych. Po drugie, T_4 **przestaje być zerowe** (0,037–0,301) – dla sumaryzatora złożonego mierzy ono rozbieżność między iloczynem brzegowych pokryć atomów a ich łącznym pokryciem; alternatywa (wiersz 2), spełniana łatwiej niż koniunkcja, ma wyraźnie wyższe T_3 i T_4 , a w efekcie najwyższe opt w trójce. Po trzecie, T_5 **maleje wraz z długością**: dwie etykiety $\Rightarrow T_5 = 0,5$, trzy $\Rightarrow T_5 = 0,25$ – to systematyczna kara za złożoność (mniejszą czytelność) zdania.

4.5 Forma II: podsumowania z kwalifikatorem

W formie drugiej kwalifikator zawęża rozważaną populację; tu ustalono „masa = ciężki”. T_1 liczone jest *warunkowo* – jaka część aut ciężkich ma daną własność. Tabela 20 pokazuje czołówkę 275 podsumowań; w odróżnieniu od formy I **aktywują się miary kwalifikatora** T_9 – T_{11} .

Tabela 20: Forma II, kwalifikator „masa własna = ciężki” – pierwsza dziesiątka spośród 275 podsumowań (ranking wg T , wagi równe). Kolumny: nr; kwantyfikator Q ; sumaryzator S ; pełen komplet miar T_1 – T_{11} ; opt. Kolumny T_9 – T_{11} (miary kwalifikatora) są tu niezerowe i stałe, bo kwalifikator jest wspólny dla wszystkich wierszy.

#	Q	S (zmienna = etykieta)	T_1	T_2	T_3	T_4	T_5	T_6	T_7	T_8	T_9	T_{10}	T_{11}	opt
1	około połowy	długość = standardowy	1,000	0,860	0,731	0,000	1,000	0,600	0,700	0,910	0,817	0,875	1,000	0,772
2	około połowy	rozstaw osi = standardowy	1,000	0,889	0,673	0,000	1,000	0,600	0,700	0,926	0,817	0,875	1,000	0,771
3	około połowy	śr. zawracania = przeciętny	1,000	0,920	0,567	0,000	1,000	0,600	0,700	0,950	0,817	0,875	1,000	0,766
4	około połowy	rozstaw osi = wydłużony	1,000	0,889	0,606	0,000	1,000	0,600	0,700	0,926	0,817	0,875	1,000	0,765
5	mniejszość	poj. bagażnika = standardowy	1,000	0,901	0,397	0,000	1,000	0,650	0,775	0,933	0,817	0,875	1,000	0,759
6	około połowy	moc silnika = przyzwoity	1,000	0,875	0,542	0,000	1,000	0,600	0,700	0,919	0,817	0,875	1,000	0,757
7	prawie żaden	poj. skokowa = małolitrażowy	1,000	0,921	0,067	0,000	1,000	0,800	0,875	0,947	0,817	0,875	1,000	0,755
8	około połowy	długość = długi	0,970	0,880	0,520	0,000	1,000	0,600	0,700	0,920	0,817	0,875	1,000	0,753
9	około połowy	poj. bagażnika = pojemny	1,000	0,833	0,572	0,000	1,000	0,600	0,700	0,883	0,817	0,875	1,000	0,753
10	około połowy	śr. zawracania = nieporęczny	1,000	0,853	0,531	0,000	1,000	0,600	0,700	0,900	0,817	0,875	1,000	0,752

Merytorycznie czołówka rysuje sylwetkę typowego *ciężkiego* auta: „Około połowy ciężkich aut ma standardową długość”, „... przyzwoitą moc”, a „Prawie żadne ciężkie auto nie ma małolitrażowego silnika” ($T_3 = 0,067$) – to ostatnie zdanie jest prawdziwe ($T_1 = 1$) i nieoczywiste: niskie pokrycie niesie tu

realną informację (ciężkie auta nie miewają małych silników). Aktywne miary kwalifikatora wynoszą $T_9 = 0,817$, $T_{10} = 0,875$ (nieprecyzyjność i kardynalność etykiety „ciężki”) oraz $T_{11} = 1,000$ (kwalifikator jednoelementowy, najkrótszy).

Skok wartości optymalnej – pułapka interpretacyjna. Wartości opt w formie II (0,75–0,77) są dużo wyższe niż w formie I ($\approx 0,52$), ale różnica jest **strukturalna, nie merytoryczna**: przy równych wagach trzy miary T_9 – T_{11} w formie I są zerowe i ciągną średnią w dół, a w formie II wnoszą $\approx 0,9$. Dlatego *rankingów optymalnych obu form nie należy porównywać między sobą* – porównania mają sens tylko wewnątrz jednej formy, albo po odpowiednim dobraniu wag (wyzerowaniu miar nieaktywnych) z poziomu GUI.

4.6 Interpretacja miar i podsumowania optymalnego

Z obliczeń wynika wyraźny podział miar wg tego, ile informacji *o danych* niosą. Jedynie T_1 (**prawdziwość**) i T_3 (**pokrycie**) silnie zależą od zawartości bazy i realnie różnicują ranking. Miary T_2, T_6, T_7, T_8 zależą głównie od konstrukcji zbiorów rozmytych (szerokości nośników), a nie od danych – pełnią rolę preferencji zwięzłości; T_5, T_{11} zależą tylko od długości wyrażen, T_4 niesie informację dopiero dla sumaryzatorów złożonych, a T_9 – T_{11} – tylko dla formy II. Stąd dwa wnioski praktyczne dla wiarygodności rankingu: (i) wysoki T_1 sam w sobie nie świadczy o wartości podsumowania – zdania typu „Prawie żaden ma [rzadką etykietę]” osiągają $T_1 = 1$ trywialnie (proporcja ≈ 0 trafia w „prawie żaden”), więc T_1 trzeba czytać łącznie z T_3 ; (ii) równe wagi faworyzują formę II (z aktywnymi T_9 – T_{11}) i karzą zdania krótkie, więc uczciwe rankingowanie wymaga porównań w obrębie jednej formy albo świadomego doboru wag pod kątem miar aktywnych w danym eksperymencie.

5 Wielopodmiotowe podsumowania lingwistyczne i ich miary jakości

Eksperyment wielopodmiotowy wykonano dla rozłącznych podmiotów $P_1 = \text{BMW}$ i $P_2 = \text{Toyota}$, wyznaczonych z atrybutu **Make**. W formach II–III użyto kwalifikatora S_2 : „masa własna = ciężki”. Aplikacja wygenerowała 910 kandydatów: 300 dla formy I, po 275 dla form II–III (po odrzuceniu tautologii, gdzie S_1 dotyczył tej samej zmiennej co S_2) oraz 60 dla formy IV. Dla podsumowań wielopodmiotowych liczono stopień prawdziwości T wg [9]; literatura nie definiuje tu pełnego zestawu miar T_1 – T_{11} .

Wybór marek BMW i Toyota nie był przypadkowy: obie grupy mają w zbiorze wystarczająco dużo rekordów, ale reprezentują inne profile konstrukcyjne. Toyota ma dużo modeli miejskich i rodzinnych, natomiast BMW częściej występuje w wersjach mocniejszych, cięższych i szybszych. Dzięki temu podsumowanie wielopodmiotowe nie jest tylko ćwiczeniem formalnym, lecz sprawdza, czy język rozmyty potrafi uchwycić różnicę, którą w danych widać po wielu atrybutach naraz.

Tabela 21: Najlepsze podsumowania wielopodmiotowe (TOP 1 dla każdej formy) dla porównania BMW (P_1) i Toyoty (P_2). Kolumna „forma” wskazuje jedną z czterech postaci podsumowań wielopodmiotowych, kolumna T – stopień prawdziwości zdania, a ostatnia kolumna podaje zdanie wygenerowane przez aplikację. Wiele wartości $T = 1,000$ oznacza, że dany stosunek stopni spełnienia idealnie wpada w nośnik użytego kwantyfikatora; nie należy tego czytać jako samodzielnej miary istotności bez interpretacji treści zdania.

Forma	#	T	Podsumowanie
I	1	1,000	Prawie żaden aut BMW w porównaniu do Toyota ma: Długość pojazdu = krótki.
II	1	1,000	Prawie wszystkie aut BMW spełniających [Masa własna = ciężki] w porównaniu do aut Toyota spełniających [Masa własna = ciężki] ma: Długość pojazdu = krótki.
III	1	1,000	Prawie żaden aut BMW, które spełniają [Masa własna = ciężki], w porównaniu do Toyota ma: Długość pojazdu = krótki.
IV	1	1,000	Wiele aut BMW niż Toyota ma: Średnica zawracania = ociężały.

Wyniki wskazują, że BMW w porównaniu z Toyotą częściej trafia w etykiety większych i mocniejszych aut. Najczytelniej pokazuje to forma IV: „średnica zawracania = ociężały”. Formy I–III dają bogatsze zdania z kwantyfikatorem, lecz wiele remisów $T = 1,000$, więc wartość T należy czytać razem z treścią zdania. Forma II porównuje ciężkie BMW z ciężkimi Toyotami, a forma III – ciężkie BMW z całą Toyotą; są to różne pytania badawcze, mimo podobnej skali wyniku.

Najważniejsza różnica między formami jest interpretacyjna. Forma I odpowiada na pytanie, jak często obiekty z P_1 mają daną własność w porównaniu z P_2 . Forma II zawęza oba podmioty kwalifikatorem, więc porównuje dwie podpopulacje tego samego typu (tu: ciężkie BMW i ciężkie Toyoty). Forma III zawęza tylko pierwszy podmiot, przez co pokazuje ciężkie BMW na tle całej Toyoty. Forma IV jest najprostsza językowo i dlatego najlepiej sprawdza się do szybkiej interpretacji, ale traci informację o tym, jaki kwantyfikator opisuje skalę różnicy.

W praktyce oznacza to, że w części wielopodmiotowej sam ranking po T jest mniej wystarczający niż w części jednopodmiotowej. Stopień prawdziwości mówi, czy zdanie pasuje do wybranego kwantyfikatora, ale nie rozstrzyga, czy zdanie jest najciekawsze poznawczo. Dlatego w tabeli pokazano po jednym najlepszym przykładzie każdej formy, a interpretację oparto na treści zdań i porównaniu ich znaczenia.

6 Dyskusja, wnioski

Z przeprowadzonych obliczeń wynikają następujące wnioski.

- **Sama prawdziwość nie wystarcza do oceny przydatności podsumowania.** Zdania typu „prawie żaden obiekt ma rzadką cechę” często osiągały $T_1 = 1,000$, bo faktycznie mało rekordów spełnia warunek. Nauczyło nas to, że T_1 trzeba czytać razem z pokryciem T_3 i treścią kwantyfikatora.

Prawdziwość mówi, czy zdanie pasuje do danych; nie mówi jeszcze, czy zdanie jest poznawczo ciekawe.

- **Najwięcej o całej bazie mówiły etykiety środkowe i dobrze pokrywające rozkład.** W rankingach jednopodmiotowych wysoko powtarzały się cechy takie jak standardowa długość, standardowy rozstaw osi, przeciętna średnica zawracania czy małoditrażowa pojemność skokowa. Oznacza to, że zbiór roboczy jest zdominowany przez typowe samochody osobowe, a nie przez skrajne konstrukcje. To nie jest założenie o rynku, tylko informacja uzyskana z policzonych pokryć i prawdziwości zdań.
- **Kwalifikator zmienia pytanie badawcze, a nie tylko zawęża tabelę wyników.** Po ustawieniu kwalifikatora „masa własna = ciężki” pojawiły się zdania, które opisują nie całą bazę, lecz profil aut ciężkich. Szczególnie pouczające jest podsumowanie o prawie braku ciężkich aut małoditrażowych: niskie pokrycie $T_3 = 0,067$ nie jest tu wadą, lecz właściwą treścią wniosku. Dowiedzieliśmy się, że dla pewnych pytań badawczych małe pokrycie może być równie informacyjne jak duże.
- **Miary strukturalne trzeba traktować jako preferencję formy, a nie jako bezpośredni opis danych.** T_2 , T_6 , T_7 i T_8 zależą głównie od szerokości nośników i kardynalności zbiorów rozmytych. Pomagają karać pojęcia zbyt szerokie lub zbyt mało specyficzne, ale nie zastępują interpretacji pokrycia i prawdziwości. Widać to szczególnie przy porównaniu formy I i II: wzrost wartości optymalnej w formie II częściowo wynika z aktywacji miar kwalifikatora T_9 – T_{11} .
- **W części wielopodmiotowej nauczyliśmy się, że jedna liczba T nie porządkuje całej wiedzy o porównaniu marek.** BMW i Toyota różnią się przede wszystkim w etykietach związanych z gabarytami i osiąganiami: BMW częściej wpada w opisy aut cięższych, szybszych i mniej zwrotnych. Jednak wiele zdań ma $T = 1,000$, więc ranking wymaga komentarza językowego. Forma IV jest najłatwiejsza do szybkiej interpretacji, ale formy I–III pozwalają odróżnić pytania o całą markę, ciężkie egzemplarze obu marek oraz ciężkie BMW na tle całej Toyoty.
- **Najbardziej wiarygodne porównania powstają wewnątrz jednej formy i przy ustalonych wagach.** Porównywanie wartości optymalnej między różnymi formami może prowadzić do fałszywych wniosków, bo różne formy aktywują inne miary albo opisują inne populacje. Z tego powodu GUI pozwala zmieniać wagi i sortowanie, ale interpretacja końcowa musi uwzględniać, jakie pytanie zadaje dana forma podsumowania.

Literatura

- [1] A. Niewiadomski, *Zbiory rozmyte typu 2. Zastosowania w reprezentowaniu informacji*, Seria „Problemy współczesnej informatyki” pod redakcją L. Rutkowskiego, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2019.

- [2] S. Zadrozny, *Zapytania nieprecyzyjne i lingwistyczne podsumowania baz danych*, EXIT, Warszawa, 2006.
- [3] A. Niewiadomski, *Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions*, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2008.
- [4] L. A. Zadeh, „The concept of a linguistic variable and its application to approximate reasoning”, *Information Sciences*, vol. 8, nr 3, ss. 199–249, 1975.
- [5] L. A. Zadeh, „A computational approach to fuzzy quantifiers in natural languages”, *Computers & Mathematics with Applications*, vol. 9, nr 1, ss. 149–184, 1983.
- [6] R. R. Yager, „A new approach to the summarization of data”, *Information Sciences*, vol. 28, nr 1, ss. 69–86, 1982.
- [7] J. Kacprzyk, R. R. Yager, „Linguistic summaries of data using fuzzy logic”, *International Journal of General Systems*, vol. 30, nr 2, ss. 133–154, 2001.
- [8] J. Islam, *Car Specification Dataset 1945–2020*, Kaggle, 2020.
<https://www.kaggle.com/datasets/jahaidulislam/car-specification-dataset-1945-2020>
- [9] A. Niewiadomski, I. Superson, „On multi-subjectivity in linguistic summarization of relational databases”, *Journal of Theoretical and Applied Computer Science*, vol. 8, nr 1, ss. 15–34, 2014.
- [10] P. Cingolani, J. Alcalá-Fdez, „jFuzzyLogic: a Java library to design fuzzy logic controllers according to the standard for fuzzy control programming”, *International Journal of Computational Intelligence Systems*, vol. 6, sup. 1, ss. 61–75, 2013.

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.