

Miary jakości podsumowań lingwistycznych T_1 – T_{11}

Definicje, wzory i interpretacje
(na podstawie monografii A. Niewiadomskiego, 2008)

Mateusz Kosowski 251558
Nikodem Nowak 251598

Miary jakości podsumowań lingwistycznych

Rozdział referuje miary jakości podsumowań lingwistycznych zdefiniowane w monografii [1], rozdz. 8.2–8.4. Pierwszych pięć miar (T_1 – T_5) odpowiada klasycznym ujęciom Yagera oraz Kacprzyka, Yagera i Zadroznego rozważanym w monografii; miary T_6 – T_{10} są oryginalną propozycją A. Niewiadomskiego, sformułowaną w sekcji 8.4 „New quality measures of linguistic summaries”. Numeracja T_i i kolejność prezentacji są zgodne z tym źródłem.

T_1 – Stopień prawdziwości (*degree of truth*)

Co mierzy. Najbardziej znana miara jakości, wprowadzona przez Yagera. Określa, w jakim stopniu prawdziwe jest zdanie podsumowujące w sensie rachunku zdań kwantyfikowanych lingwistycznie Zadeha; interpretowana jako „poziom zaufania” do podsumowania.

Wzór – pierwsza forma „ Q P are/have S ” (bez kwalifikatora).

$$T_1(Q \text{ } P \text{ are/have } S) = \mu_Q\left(\frac{r}{M}\right), \quad r = \sum_{i=1}^m \mu_S(d_i), \quad (1)$$

gdzie $M = m$ dla kwantyfikatora *względny* i $M = 1$ dla *bezwzględnego*. Funkcję μ_S dla sumaryzatora złożonego $S = S_1 \text{ AND/OR } \dots \text{ AND/OR } S_n$ wyznacza się operatorami t-normy t (AND) i t-conormy s (OR) na cylindrycznych rozszerzeniach do produktu uniwersów:

$$\mu_S(d_i) = \mu_{S_1}(d_i) \text{ } t/s \text{ } \mu_{S_2}(d_i) \text{ } t/s \text{ } \dots \text{ } t/s \text{ } \mu_{S_n}(d_i). \quad (2)$$

Wzór – druga forma „ Q P being/having W are/have S ” (z kwalifikatorem).

$$T_1(Q \text{ } P \text{ being/having } W \text{ are } S) = \mu_Q\left(\frac{\sum_{i=1}^m (\mu_S(d_i) \wedge \mu_W(d_i))}{\sum_{i=1}^m \mu_W(d_i)}\right). \quad (3)$$

W mianowniku stoi $\Sigma\text{-count}(W)$ – liczone są tylko krotki o niezerowej przynależności do kwalifikatora. W tej formie **możliwy jest tylko kwantyfikator względny**, ponieważ wartość ułamka jest z natury proporcją.

Interpretacja. $T_1 \in [0, 1]$. Im wyższa wartość, tym podsumowanie jest bardziej prawdziwe (informatywne). Wartość $T_1 = 0$ oznacza zdanie zupełnie nietrafne, a $T_1 = 1$ – w pełni potwierdzone przez zawartość bazy.

T_2 – Stopień nieprecyzyjności (*degree of imprecision*)

Co mierzy. Ocenia, jak nieprecyzyjny jest *sumaryzator*, na podstawie stopnia rozmycia (in) zbiorów rozmytych go tworzących. Im szerszy nośnik zbiorów S_j , tym bardziej rozmyty (ogólny) sumaryzator.

Wzór.

$$T_2 = 1 - \left(\prod_{j=1}^n \text{in}(S_j) \right)^{1/n}, \quad \text{in}(S_j) = \frac{|\text{supp}(S_j)|}{|\mathcal{X}_j|}. \quad (4)$$

Dla sumaryzatora prostego ($n = 1$) wzór upraszcza się do $T_2 = 1 - \text{in}(S)$.

Interpretacja. $T_2 \in [0, 1]$. Im wyższa wartość, tym precyzyjniejszy (węższy) *sumaryzator*, czyli lepsze podsumowanie. T_2 to dopełnienie średniej geometrycznej stopni rozmycia – gdy $\text{in}(S_j)$ rośnie, T_2 maleje.

T_3 – Stopień pokrycia (*degree of covering*)

Co mierzy. Mówi, jaka część krotek pasujących (choćby częściowo) do kwalifikatora W jest jednocześnie pokryta przez sumaryzator S . Pierwotnie zdefiniowana dla podsumowań drugiej formy.

Wzór.

$$T_3 = \frac{\sum_{i=1}^m t_i}{\sum_{i=1}^m h_i}, \quad (5)$$

$$t_i = \begin{cases} 1, & \mu_S(d_i) > 0 \wedge \mu_W(d_i) > 0 \\ 0, & \text{w.p.p.} \end{cases}, \quad h_i = \begin{cases} 1, & \mu_W(d_i) > 0 \\ 0, & \text{w.p.p.} \end{cases}. \quad (6)$$

Liczone są ostre wskaźniki należenia do nośnika, nie wartości μ .

Dla pierwszej formy (bez kwalifikatora) traktuje się ją jako szczególny przypadek, w którym $W = \mathcal{D}$ („być w bazie”), zatem $h_i^* = 1$ dla wszystkich krotek, co daje:

$$T_3^* = \frac{|\{i : \mu_S(d_i) > 0\}|}{m} = \frac{|\text{supp}(S \cap \mathcal{D})|}{m}. \quad (7)$$

Interpretacja. $T_3 \in [0, 1]$. Im wyższa wartość, tym więcej rekordów wpadających do kwalifikatora jest opisanych przez sumaryzator. Bardzo niskie wartości oznaczają, że zdanie odnosi się do pomijalnie małej części populacji (kwalifikator filtruje dużo, sumaryzator pokrywa mało).

T_4 – Stopień trafności (*degree of appropriateness*)

Co mierzy. Sprawdza, czy podsumowanie jest *nietrywialne* – czy mówi coś, czego nie dałoby się przewidzieć z samych częstości brzegowych poszczególnych etykiet. Porównuje rzeczywiste pokrycie T_3 z iloczynem brzegowych częstości składowych sumaryzatora (oczekiwanym pokryciem przy „niezależności” cech).

Wzór.

$$r_j = \frac{\sum_{i=1}^m g_{ij}}{m}, \quad g_{ij} = \begin{cases} 1, & \mu_{S_j}(V_j(y_i)) > 0 \\ 0, & \text{w.p.p.} \end{cases}, \quad (8)$$

$$T_4 = \left| \prod_{j=1}^n r_j - T_3 \right|. \quad (9)$$

r_j – udział rekordów spełniających pojedynczą j -tą etykietę sumaryzatora; $\prod_j r_j$ – „oczekiwane” pokrycie przy założeniu niezależności składowych.

Interpretacja. $T_4 \in [0, 1]$. Im większa wartość, tym bardziej trafne (odkrywcze) podsumowanie – pokrycie znacząco różni się od oczekiwanego, co wskazuje na korelację cech ujętą przez konkretny spójnik AND/OR. T_4 bliskie zera oznacza, że pokrycie jest dokładnie takie, jak gdyby cechy były niezależne – zdanie nie odkrywa nowej informacji.

T_5 – Długość podsumowania (*length of summary*)

Co mierzy. Karze podsumowania zbyt rozbudowane: im więcej zbiorów rozmytych sklejonych spójnikami AND/OR tworzy sumaryzator S , tym mniej czytelne (i mniej wartościowe) staje się zdanie.

Wzór.

$$T_5 = 2 \cdot (0,5)^{|S|}, \quad (10)$$

gdzie $|S|$ to liczba zbiorów rozmytych, z których złożony jest sumaryzator (uwaga: tu $|S|$ oznacza licznik składowych, a nie miarę zbioru rozmytego). Wartości: $|S| = 1 \Rightarrow T_5 = 1$, $|S| = 2 \Rightarrow T_5 = 0,5$, $|S| = 3 \Rightarrow T_5 = 0,25$, itd.

Interpretacja. $T_5 \in (0, 1]$. Im wyższa wartość, tym krótsze (zwięźlejsze) podsumowanie, czyli lepsze. Nie istnieją wartości spoza tego przedziału – T_5 zawsze ma postać $2^{1-|S|}$.

T_6 – Stopień nieprecyzyjności kwantyfikatora (*degree of quantifier imprecision*)

Co mierzy. Pierwsza z miar oryginalnie zaproponowanych przez Niewiadomskiego [1], sekcja 8.4.1. Analogiczna do T_2 , ale dotyczy kształtu zbioru rozmytego Q reprezentującego *kwantyfikator*, a nie sumaryzator. Im szerszy nośnik Q , tym mniej precyzyjny opis ilościowy.

Wzór.

$$T_6 = 1 - \ln(Q) = 1 - \frac{|\text{supp}(Q)|}{|\mathcal{X}_Q|}. \quad (11)$$

Mianownik sprowadza się do dwóch przypadków:

- **kwantyfikator względny:** $|\mathcal{X}_Q| = 1$, bo $\mathcal{X}_Q = [0, 1]$;
- **kwantyfikator bezwzględny:** $|\mathcal{X}_Q| = m$, czyli liczba krotek w bazie.

Interpretacja. $T_6 \in [0, 1]$. Im wyższa wartość, tym węższy nośnik kwantyfikatora, czyli tym bardziej precyzyjny opis „ile”. Dla kwantyfikatorów ostrych (np. EXACTLY 30 – singleton $\{1,0/30\}$, lub FOR ALL – $\{1,0/1\}$) zachodzi $T_6 = 0$, co intuicyjnie oznacza ich pełną precyzję na własnym uniwersum.

T_7 – Stopień kardynalności kwantyfikatora (*degree of quantifier cardinality*)

Co mierzy. Druga miara Niewiadomskiego [1], sekcja 8.4.2. Inspirowana obserwacją, że im większa kardynalność $|Q|$, tym mniej precyzyjny kwantyfikator. *Subtelnie różna od T_6 :* T_6 używa miary nośnika Q , T_7 – miary samego zbioru rozmytego, dzięki czemu rozróżnia kwantyfikatory o tym samym nośniku, lecz różnym kształcie (np. trójkąt vs. trapez na tym samym przedziale).

Wzór.

$$T_7 = 1 - \frac{|Q|}{|\mathcal{X}_Q|}, \quad (12)$$

gdzie $|Q| = \int \mu_Q(x) dx$ (miara całkowita funkcji przynależności) lub $\sum_x \mu_Q(x)$ (sigma-count) dla zbiorów skończonych. Mianownik tak samo jak w T_6 : $|\mathcal{X}_Q| = 1$ (względny) lub m (bezwzględny).

Interpretacja. $T_7 \in [0, 1]$. Im wyższa wartość, tym mniejsza miara $|Q|$, czyli „smuklejszy” kwantyfikator – bardziej precyzyjny.

T_8 – Stopień kardynalności sumaryzatora (*degree of summarizer cardinality*)

Co mierzy. Trzecia miara Niewiadomskiego [1], sekcja 8.4.3. Ocenia łączną „smukłość” sumaryzatora przez średnią geometryczną znormalizowanych miar zbiorów rozmytych $S_1, \dots, S_n$. Im mniejsze miary $|S_j|$ względem swoich uniwersów, tym precyzyjniej etykiety opisują wartości atrybutów.

Wzór.

$$T_8 = 1 - \left(\prod_{j=1}^n \frac{|S_j|}{|\mathcal{X}_j|} \right)^{1/n}. \quad (13)$$

Interpretacja. $T_8 \in [0, 1]$. Im wyższa wartość, tym węższe (selektywniejsze) poszczególne etykiety na swoich uniwersach. **Uwaga:** normalizacja zachodzi przez *uniwersum atrybutu* $|\mathcal{X}_j|$, a nie przez liczbę rekordów w bazie. T_8 ocenia szerokość zbiorów na osi atrybutu, a nie ich realną kardynalność „w bazie”.

T_9 – Stopień nieprecyzyjności kwalifikatora (*degree of qualifier imprecision*)

Co mierzy. Czwarta miara Niewiadomskiego [1], sekcja 8.4.4. Określona dla podsumowań drugiej formy „ Q P being W are S ”. Analogon T_2 i T_6 : ocenia szerokość nośników zbiorów rozmytych tworzących *kwalifikator* W .

Wzór – kwalifikator prosty.

$$T_9 = 1 - \ln(W), \quad (14)$$

gdzie $\ln(W) = |\text{supp}(W)|/|\mathcal{X}_W|$.

Wzór – kwalifikator złożony z $W_{g_1}, \dots, W_{g_x}$ na uniwersach $\mathcal{X}_{g_1}, \dots, \mathcal{X}_{g_x}$.

$$T_9 = 1 - \left(\prod_{j=1}^x \ln(W_{g_j}) \right)^{1/x}. \quad (15)$$

Interpretacja. $T_9 \in [0, 1]$. Im wyższa wartość, tym węższy (precyzyjniej zdefiniowany) kwalifikator – zdanie filtruje szczegółowo określoną podgrupę obiektów.

T_{10} – Stopień kardynalności kwalifikatora (*degree of qualifier cardinality*)

Co mierzy. Piąta miara Niewiadomskiego [1], sekcja 8.4.5. Bazuje na kardynalności (mierze) zbiorów W_{g_j} . Względem T_9 relacja taka sama jak T_7 względem T_6 : rozróżnia kwalifikatory o tym samym nośniku, lecz różnym kształcie.

Wzór – kwalifikator prosty.

$$T_{10} = 1 - \frac{|W|}{|\mathcal{X}_g|}. \quad (16)$$

Wzór – kwalifikator złożony.

$$T_{10} = 1 - \left(\prod_{j=1}^x \frac{|W_{g_j}|}{|\mathcal{X}_{g_j}|} \right)^{1/x}. \quad (17)$$

Interpretacja. $T_{10} \in [0, 1]$. Im wyższa wartość, tym mniejsza miara $|W_{g_j}|$ względem $|\mathcal{X}_{g_j}|$ – „smuklejszy” kwalifikator. **Uwaga:** tak jak T_8 , miara normalizowana jest przez uniwersum atrybutu, a nie przez liczbę rekordów w bazie. Nie mówi więc, ilu rekordów dotyczy kwalifikator, tylko jak wąsko jest on określony na osi swojego atrybutu.

Łączna jakość podsumowania (*goodness of the summary*)

Łączną miarę jakości definiuje się jako średnią ważoną składowych miar T_i [1, wzór (8.74)]:

$$T = T(T_1, \dots, T_{10}; w_1, \dots, w_{10}) = \sum_{i=1}^{10} w_i \cdot T_i, \quad \sum_{i=1}^{10} w_i = 1. \quad (18)$$

Optymalne podsumowanie wybiera się jako:

$$S^* = \arg \max_{S \in \mathbb{S}} \sum_{i=1}^{10} w_i \cdot T_i. \quad (19)$$

Autor zaleca (gdy nic innego nie wpływa na wybór wag) ustawienie $w_1 = w_2 = w_4 = w_5 = w_6 = w_7 = w_8 (= w_3)$ dla podsumowań pierwszej formy oraz $w_1 = \dots = w_{10}$ dla podsumowań drugiej formy (jednakowe wagi dla wszystkich miar).

T_{11} – Długość kwalifikatora (*length of qualifier*)

TODO. Miara nie pojawia się w monografii Niewiadomskiego [1] – rozdz. 8.4 i zbiorczy wzór (8.74) obejmują wyłącznie T_1 – T_{10} . T_{11} jest najpewniej rozszerzeniem narzuconym przez prowadzącego (analogon T_5 dla kwalifikatora). Spodziewana postać przez analogię:

$$T_{11} = 2 \cdot (0,5)^{|W|},$$

gdzie $|W|$ to liczba zbiorów rozmytych tworzących kwalifikator. Po znalezieniu wzoru w treści projektu lub materiałach prowadzącego sekcję uzupełnić.

Literatura

- [1] Niewiadomski, A.: *Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions*. Akademicka Oficyna Wydawnicza EXIT, Warszawa 2008, ISBN 978-83-60434-40-6. Seria: Badania Systemowe, t. 60, Instytut Badań Systemowych PAN.